TÀI LIỆU ĐỌC HIỂU / 26.10.2026

DeepNeoAG

Báo cáo giải thích theo từng slide v3

38 slide / 4 phần chính / có giải thích phụ lục

Từ câu hỏi nghiên cứu đến kết quả thực nghiệm

Tài liệu giải thích từng slide đang trình bày điều gì, vì sao các bước được thực hiện và kết luận nào được bằng chứng hỗ trợ. Bản v3 dùng bộ slide đã hoàn thiện ba sơ đồ I, C, D; diễn giải bằng tiếng Việt và giữ tên mô hình để dễ đối chiếu.

Bức tranh kết quả

Hồ sơ gồm 22 cấu hình và 258 lần fit trên split công bố. ESM 35M + MCNN đạt AP test cao nhất quan sát được (0.5758), trong khi one-hot MCNN là mốc chi phí thấp đáng chú ý (AP 0.5408, 28.801 tham số). Chênh lệch giữa các mô hình mạnh còn bất định.

Phạm vi bằng chứng

Báo cáo tổng hợp dữ liệu và kết quả đã có, không huấn luyện lại. Số liệu được đối chiếu với full-run report và các bảng lưu trong dự án. Giới hạn về similarity, calibration, 61 mẫu dương test và provenance của source được giữ rõ trong phần kết luận.

Nguồn trình tự: DeepNeoAG_Operating_Review_2026-10-26_v3.pdf. Số slide trong tài liệu luôn là số trang của bộ PDF v3 này.

Mục lục theo từng slide

Bấm một dòng để đến phần giải thích. Trang của báo cáo khác số slide; cột trái luôn giữ số slide gốc.

SLIDE	NỘI DUNG GIẢI THÍCH	TRANG
01	Câu hỏi xuyên suốt của dự án	5
02	Introduction: xác định đúng điều cần dự đoán	6
03	Vì sao trình tự peptide là một đầu vào đáng nghiên cứu?	7
04	Đầu vào, điểm số và quyết định nhị phân	8
05	Vì sao cần năm cách tiếp cận độc lập?	9
06	Methodology: các quyết định tạo nên phép so sánh	10
07	Nguồn dữ liệu và ranh giới train/test	11
08	Kiểm tra dữ liệu đã dẫn đến lựa chọn triển khai nào?	12
09	Vai trò khác nhau của fitting, early stopping, OOF và test	13
10	Metric đo điều gì và vì sao ngưỡng phải được báo cáo?	14
11	Baseline composition: điều gì bị mất khi chỉ đếm amino acid?	15
12	One-hot MCNN: học mẫu cục bộ trực tiếp từ nhãn	16
13	ESM embeddings và ý nghĩa chính xác của B, L, D	17
14	Cùng một embedding, ba cách khai thác thông tin	18
15	Ma trận thí nghiệm được tổ chức theo từng yếu tố	19
16	Các cấu hình đã khóa trước test	20
17	Results: đánh giá quan sát cùng độ ổn định và chi phí	21
18	Learning curves cho biết mô hình đã học và dừng thế nào?	22
19	Mean CV AP và độ phân tán mô tả	23
20	Các điểm fold/seed bộc lộ điều gì mà mean che khuất?	24
21	Ablation: thay một yếu tố đã tạo ra thay đổi nào?	25
22	Tách hiệu ứng biểu diễn khỏi lợi ích của tuning	26
23	Encoder lớn hơn có lợi nhất quán không?	27
24	Test độc lập kiểm tra những lựa chọn đã khóa	28
25	Đọc toàn bộ bảng test thay vì chỉ một cột tô xanh	29
26	Phân biệt bootstrap uncertainty với seed variability	30
27	PR và ROC là hai góc nhìn của cùng bộ score	31
28	Confusion matrices chuyển tỷ lệ thành số đếm kiểm tra được	32
29	Conclusion: tổng hợp điều đã biết và phần còn mở	33
30	Hai lỗi cụ thể có ý nghĩa gì?	34
31	Kiểm tra số liệu và xác nhận đúng source là hai mức khác nhau	35
32	Những bài học đã đạt được và thí nghiệm kế tiếp	36
33	Phụ lục CV (1/2): vì sao cần giữ cả cấu hình không được chọn?	37
34	Phụ lục CV (2/2): capacity, loss và encoder lớn hơn	38
35	Learning histories đầy đủ: bằng chứng chi tiết phía sau slide 18	39
36	Ablation đầy đủ: kiểm tra các điều kiện giữ cố định	40
37	Ví dụ lỗi bổ sung và cách lựa chọn có thể tái kiểm tra	41
38	Tài liệu tham khảo và nguồn gốc hình ảnh	42

Toàn bộ quá trình đi theo logic nào?

Mạch nghiên cứu là câu hỏi - thay đổi có kiểm soát - quan sát - bài học. Các bước dưới đây là trình tự logic của hồ sơ thực nghiệm, không phải hướng dẫn thao tác chạy code trong tài liệu này.

Bước	Việc đã làm	Dấu vết trong slide
1. Xác định endpoint	Đầu vào chỉ là sequence; phân biệt score, ranking và nhãn	3-5
2. Bảo toàn và audit dữ liệu	Giữ split công bố, kiểm tra trùng chính xác và mẫu dài 35	7-8
3. Thiết kế đánh giá	Shared CV, inner early stopping, OOF, khóa threshold	9-10
4. Xây các biểu diễn và head	Composition, one-hot, frozen ESM, LR/CNN/MCNN	11-16
5. Fit và phân tích train	258 fit, learning histories, ablation, fold/seed, cost	18-23
6. Kiểm tra độc lập	Đánh giá lựa chọn đã khóa trên 1.404 mẫu test	24-28
7. Đánh giá giới hạn	Xem lỗi, uncertainty, provenance và bước kế tiếp	30-32

Cách phân biệt phát biểu

“Đã làm” chỉ một bước có hồ sơ hoặc artefact lưu lại. “Quan sát được” chỉ số đo trên dữ liệu hiện có. “Chưa chứng minh” là giới hạn của suy luận. “Đề xuất tiếp theo” chưa phải một thí nghiệm đã hoàn thành.

Mỗi trang giải thích có hình slide gốc thu nhỏ, phần diễn giải, một ý cần nắm và mã nguồn [S...]. Mã nguồn được giải nghĩa ở cuối báo cáo. Các trang chuyển phần vẫn có mục riêng để giữ đủ thứ tự 38 slide.

Những khái niệm cần nắm trước

Thuật ngữ	Cách hiểu trong dự án
Fit / epoch / refit	Fit là một lần học một mô hình. Epoch là một lượt qua dữ liệu fitting. Refit học lại lựa chọn cuối bằng toàn bộ train.
CV / fold / OOF	CV chia train thành các fold. OOF ghép dự đoán của các record ở vai trò outer-validation, không được fit bởi mô hình tạo dự đoán đó.
Seed / ensemble	Seed thay đổi khởi tạo. Neural ensemble lấy mean score của ba seed theo từng peptide, rồi mới tính metric.
Embedding / frozen encoder	Embedding là vector biểu diễn residue. Frozen nghĩa là trọng số ESM không được cập nhật bằng nhãn của bài toán.
AP / ROC-AUC	Metric của thứ hạng score. AP ở đây là average_precision_score. Thay ngưỡng nhị phân không đổi hai giá trị này.
Precision / recall	Precision trả lời “dự đoán dương đúng bao nhiêu?”. Recall trả lời “tìm được bao nhiêu dương thật?”.
MCC / confusion matrix	MCC tổng hợp TN, FP, FN, TP tại một threshold. Confusion matrix cho biết số đếm cụ thể.
SD / CI / paired CI	SD fold/seed là spread mô tả. Bootstrap CI mô tả lấy mẫu test có điều kiện. Paired CI xét trực tiếp chênh lệch hai mô hình trên cùng ID.
Calibration / similarity	Calibration kiểm tra score có đáng hiểu như xác suất hay không. Kiểm tra similarity mạnh hơn kiểm tra chuỗi trùng hoàn toàn.

Quy tắc đọc một kết quả

Luôn hỏi: split nào, cấu hình nào, metric nào, threshold nào, ensemble hay single-seed, mẫu số bao nhiêu và uncertainty được tính như thế nào. Các con số có cùng tên metric vẫn có thể thuộc những phép tổng hợp khác nhau.

SLIDE 01

Câu hỏi xuyên suốt của dự án

DeepNeoAG: Learning Through Controlled Experiments



Mục đích nghiên cứu. DeepNeoAG được trình bày như một chuỗi thí nghiệm về phân loại peptide bằng trình tự amino acid. Câu hỏi chính là: thay đổi cách biểu diễn chuỗi và bộ phân loại phía sau ảnh hưởng như thế nào đến khả năng xếp hạng, phát hiện mẫu dương và chi phí tính toán? Tên bài nhấn mạnh việc học từ các thay đổi có kiểm soát, thay vì chỉ tìm một điểm số cao nhất.

Phạm vi đã thực hiện. Hồ sơ thực nghiệm đầy đủ ghi nhận 7.012 peptide, tám họ mô hình, 22 cấu hình và 258 lần fit. Năm cách tiếp cận cốt lõi đi từ thành phần amino acid đến one-hot MCNN rồi đến các biểu diễn ESM với pooling, CNN và MCNN. Ba biến thể ESM 35M mở rộng việc so sánh kích thước encoder.

Cách đọc toàn bộ báo cáo. Introduction xác định bài toán. Methodology giải thích dữ liệu, biểu diễn và đánh giá. Results đối chiếu hiệu năng với độ biến thiên và chi phí. Conclusion tổng hợp điều đã biết và giới hạn còn lại. Đây là phân tích hồ sơ chạy đã cung cấp; việc biên soạn báo cáo không tạo ra một lần huấn luyện GPU mới.

> **Ý cần nắm:** Thành quả trung tâm là một phép so sánh có thể truy vết, không phải bằng chứng về hiệu quả điều trị.

Minh chứng: [S1], [S2], [S3]. Hình đối chiếu: slide 1 của PDF v3.

SLIDE 02

Introduction: xác định đúng điều cần dự đoán

Introduction



Vai trò của phần mở đầu. Slide này là trang chuyển phần. Nó đặt ba nội dung tiếp theo vào cùng một khung: động cơ sinh học, định nghĩa đầu vào/đầu ra và các câu hỏi dẫn đến lựa chọn mô hình. Chưa có kết luận thực nghiệm nào được đưa ra ở đây.

Mối liên hệ với quy trình. Nếu chưa phân biệt được phân loại theo nhãn của bộ dữ liệu với xác nhận đáp ứng miễn dịch, người đọc rất dễ diễn giải quá mức kết quả. Phần mở đầu vì vậy xác định ranh giới trước khi bàn đến ESM, CNN hay điểm AP. Các bước tiếp theo đều phải được hiểu trong ranh giới này.

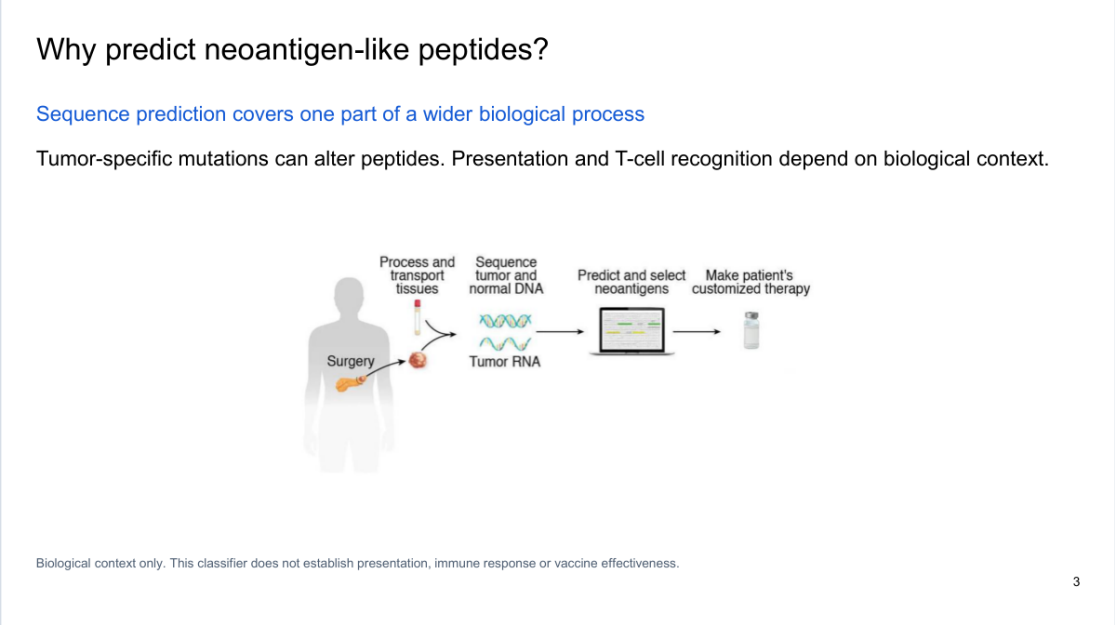
> **Ý cần nắm:** Một mô hình chỉ trả lời được câu hỏi mà dữ liệu đầu vào và nhãn cho phép.

Minh chứng: [S1], [S2]. Hình đối chiếu: slide 2 của PDF v3.

SLIDE 03

Vì sao trình tự peptide là một đầu vào đáng nghiên cứu?

Why predict neoantigen-like peptides?



Bối cảnh sinh học. Đột biến đặc hiệu của khối u có thể làm thay đổi peptide. Tuy nhiên, từ một trình tự đến sự trình diện qua MHC và nhận diện bởi tế bào T còn có nhiều điều kiện sinh học khác. Mô hình trong dự án chỉ quan sát trình tự, không quan sát đầy đủ các điều kiện đó.

Vai trò của hình minh họa. Hình trên slide đặt dự đoán ứng viên vào một quy trình nghiên cứu neoantigen rộng hơn. Nó là hình bối cảnh, không phải sơ đồ toàn bộ hệ thống mà dự án đã xây dựng. Dự án không thực hiện các bước lấy mẫu bệnh nhân, thiết kế vaccine hoặc kiểm chứng đáp ứng miễn dịch trong hình.

Ý nghĩa đối với kết quả. Một bộ xếp hạng tốt có thể hữu ích cho việc ưu tiên ứng viên nghiên cứu, nhưng kết quả phân loại trên bộ dữ liệu không đủ để khẳng định peptide được trình diện tự nhiên hoặc gây miễn dịch. Vì vậy, báo cáo dùng thuật ngữ “neoantigen-like” và luôn gắn phát biểu với nhãn, split và protocol đang xét.

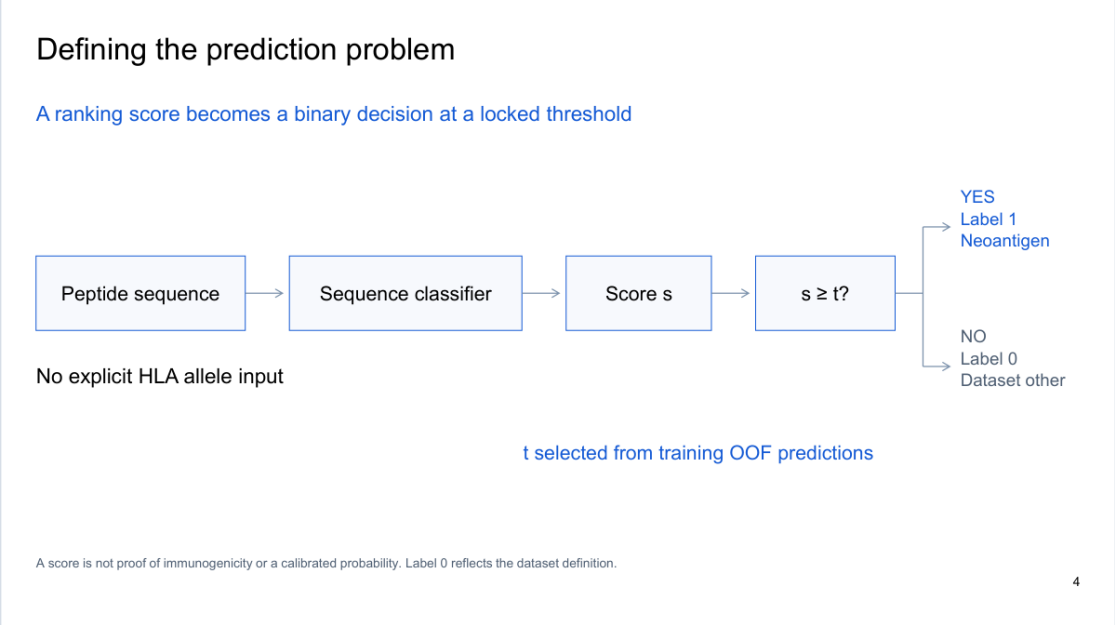
> **Ý cần nắm:** Động cơ sinh học giải thích vì sao bài toán có ý nghĩa; nó không tự xác nhận ý nghĩa sinh học của từng dự đoán.

Minh chứng: [S1], [S2], [S9]. Hình đối chiếu: slide 3 của PDF v3.

SLIDE 04

Đầu vào, điểm số và quyết định nhị phân

Defining the prediction problem



Bài toán cụ thể. Đầu vào là một chuỗi amino acid, không có allele HLA được đưa vào tường minh. Nhãn 1 là nhóm neoantigen theo nguồn dữ liệu, còn nhãn 0 là nhóm “other”. Nhãn 0 không đồng nghĩa với mọi peptide chắc chắn không có tính sinh miễn dịch trong mọi bối cảnh.

Hai loại đầu ra. Bộ phân loại tạo điểm số s để sắp xếp các peptide. Muốn chuyển thành nhãn nhị phân, cần một ngưỡng t: s lớn hơn hoặc bằng t thì dự đoán 1. Xếp hạng và phân loại ở một ngưỡng là hai việc khác nhau. AP đánh giá thứ tự điểm số, trong khi precision, recall và MCC còn phụ thuộc vào t.

Quyết định đã khóa. Ngưỡng được chọn bằng các dự đoán out-of-fold trên dữ liệu train, theo tiêu chí MCC. Sau đó ngưỡng và cấu hình được khóa trước đánh giá test. Điểm gần 1 vẫn chưa phải một xác suất sinh miễn dịch đã hiệu chuẩn; dự án chưa đánh giá calibration cho cách diễn giải đó.

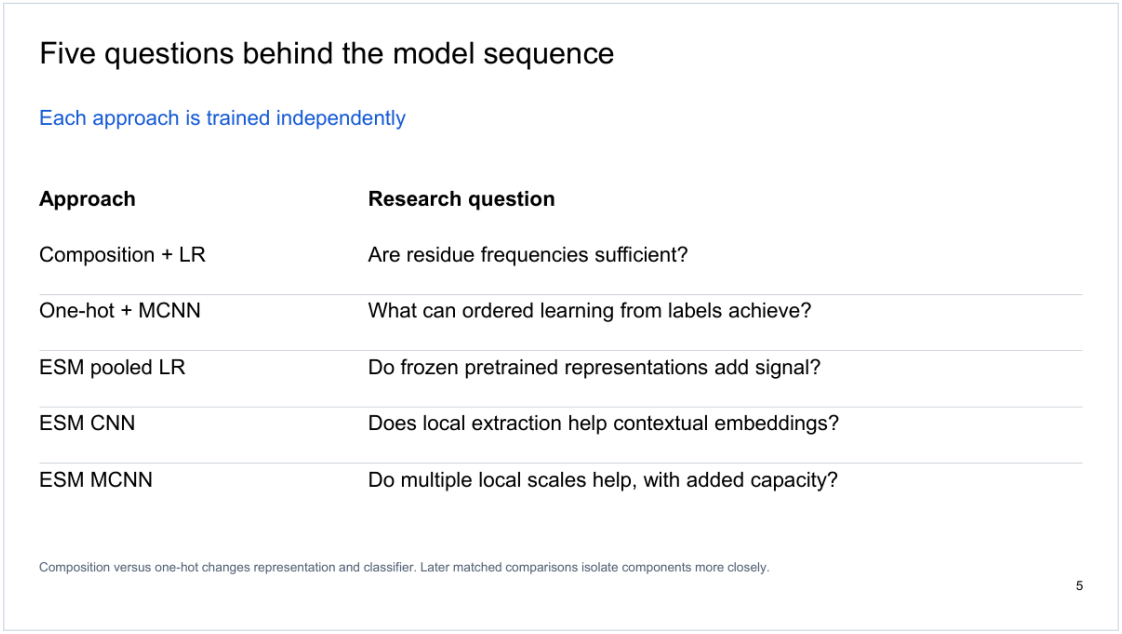
> **Ý cần nắm:** Điểm số, thứ hạng và nhãn sau ngưỡng là ba khái niệm liên quan nhưng không thể dùng thay cho nhau.

Minh chứng: [S2], [S3], [S5]. Hình đối chiếu: slide 4 của PDF v3.

SLIDE 05

Vì sao cần năm cách tiếp cận độc lập?

Five questions behind the model sequence



Logic của chuỗi mô hình. Composition + LR hỏi liệu chỉ tần suất các amino acid đã đủ hay chưa. One-hot + MCNN kiểm tra khả năng học các mẫu có thứ tự trực tiếp từ nhãn. ESM pooled LR kiểm tra tín hiệu trong biểu diễn pretrained. ESM CNN bổ sung phép trích xuất cục bộ, còn ESM MCNN kết hợp nhiều kích thước cửa sổ.

Quan hệ giữa các phương pháp. Các hàng trên slide là những mô hình được fit độc lập. Đây không phải pipeline trong đó dự đoán của mô hình trước được truyền sang mô hình sau. Việc chúng xuất hiện theo thứ tự tăng độ phức tạp chỉ nhằm làm rõ câu hỏi nghiên cứu.

Giới hạn của so sánh. Từ composition LR sang one-hot MCNN đồng thời thay biểu diễn và bộ phân loại, nên không thể quy toàn bộ chênh lệch cho việc giữ thứ tự chuỗi. Tương tự, MCNN vừa thêm nhiều cửa sổ vừa thêm tham số. Các ablation ở phần sau giúp kiểm tra từng yếu tố gần hơn, nhưng chưa loại bỏ mọi yếu tố gây nhiễu.

> **Ý cần nắm:** Mỗi mô hình tồn tại để kiểm tra một câu hỏi; tăng độ phức tạp không tự bảo đảm tiến bộ.

Minh chứng: [S2], [S3]. Hình đối chiếu: slide 5 của PDF v3.

SLIDE 06

Methodology: các quyết định tạo nên phép so sánh

Methodology



Vai trò của phần phương pháp. Trang chuyển phần này mở đầu quá trình đi từ dữ liệu đến một kết quả đánh giá đáng diễn giải. Các slide 7-16 giải thích nguồn dữ liệu, kiểm tra dữ liệu, split, metric, biểu diễn, kiến trúc, ma trận thí nghiệm và cấu hình được chọn.

Điểm quyết định. Chất lượng của một so sánh không chỉ phụ thuộc vào kiến trúc. Những lựa chọn như fit scaler ở đâu, dùng tập nào để early stopping, mask padding ra sao và chọn ngưỡng bằng dữ liệu nào đều có thể làm thay đổi ý nghĩa của điểm số. Đây là lý do Methodology được trình bày trước các bảng kết quả.

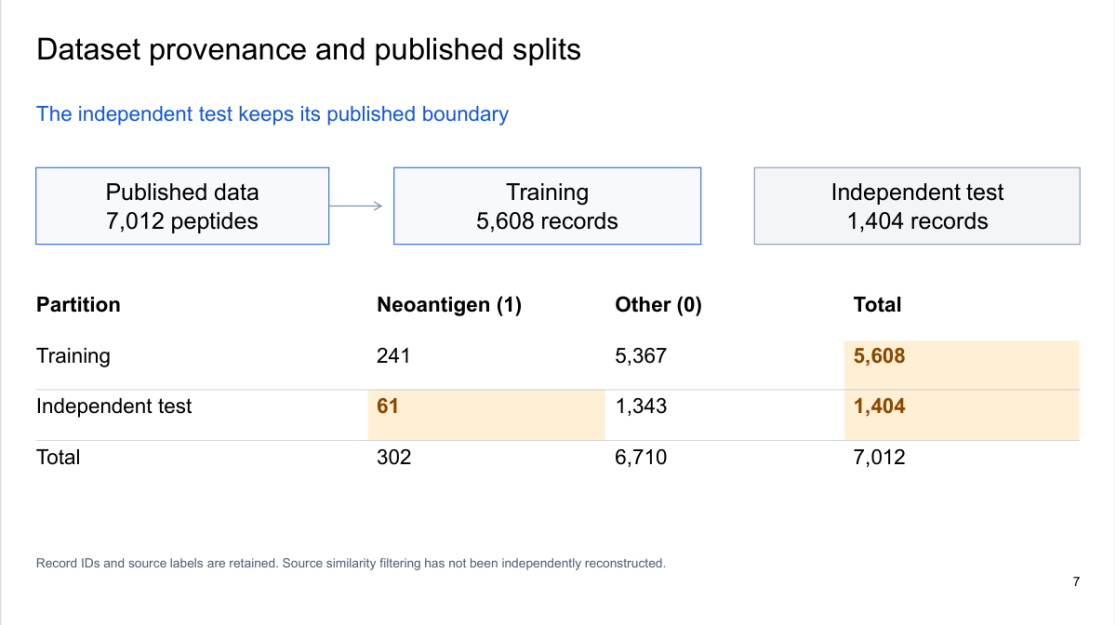
> **Ý cần nắm:** Phần phương pháp xác định điểm số được tạo ra như thế nào và ta được phép kết luận đến đâu.

Minh chứng: [S1], [S3]. Hình đối chiếu: slide 6 của PDF v3.

SLIDE 07

Nguồn dữ liệu và ranh giới train/test

Dataset provenance and published splits



Dữ liệu đã sử dụng. Bộ cuối cùng có 7.012 peptide: 302 neoantigen và 6.710 other. Split công bố gồm 5.608 mẫu train với 241 dương, và 1.404 mẫu test với 61 dương. Dự án giữ split này, không trộn toàn bộ rồi chia lại để có kết quả thuận lợi hơn.

Cách bảo toàn nguồn gốc. ID, trình tự, nhãn, chiều dài và đường dẫn file nguồn được giữ lại. README dữ liệu ghi commit nguồn cố định; hồ sơ review đối chiếu các CSV đã dùng trong run với CSV của dự án. Nhờ đó, số lượng và các trường dữ liệu có thể truy ngược về nguồn thay vì chỉ dựa trên một mô tả tổng hợp.

Vì sao các ô cam quan trọng. Ô 61 nhấn mạnh lượng mẫu dương test rất nhỏ. Hai tổng 5.608 và 1.404 xác định ranh giới giữa phát triển và đánh giá cuối. Tác giả nguồn có báo cáo lọc similarity, nhưng dự án chưa tái dựng độc lập bước lọc này; giữ split công bố không tự chứng minh hai phía độc lập về tương đồng trình tự.

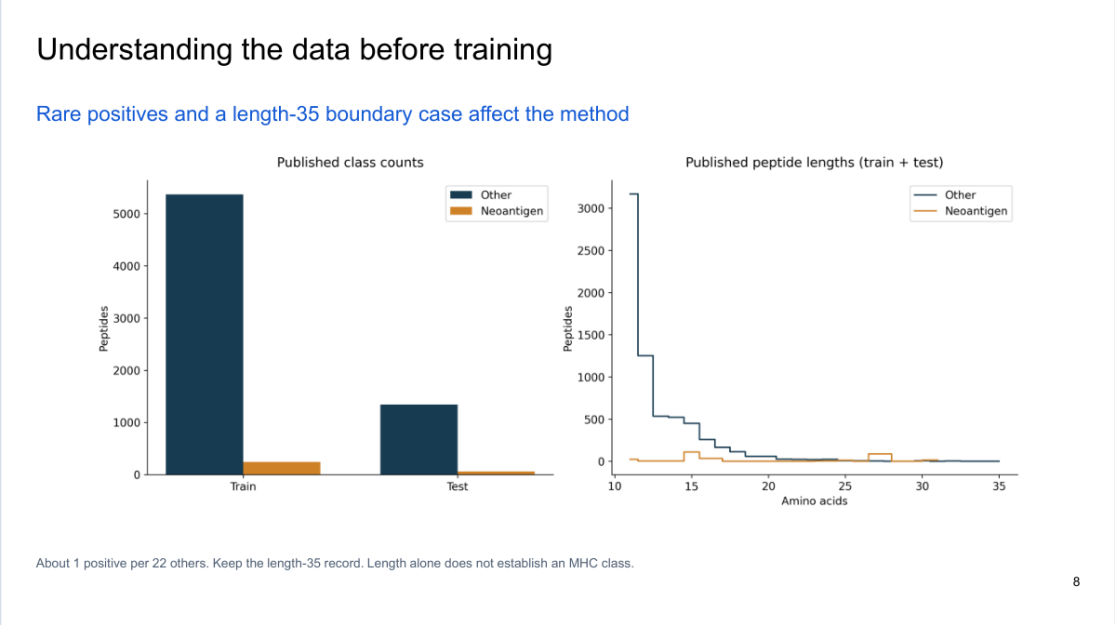
> **Ý cần nắm:** Split công bố được bảo toàn, nhưng sự độc lập về homology vẫn cần một kiểm tra riêng.

Minh chứng: [S2], [S4], [S10]. Hình đối chiếu: slide 7 của PDF v3.

SLIDE 08

Kiểm tra dữ liệu đã dẫn đến lựa chọn triển khai nào?

Understanding the data before training



Cách đọc hai biểu đồ. Biểu đồ trái cho thấy nhóm other áp đảo ở cả train và test. Biểu đồ phải mô tả phân bố chiều dài của hai nhãn, giúp hiểu vì sao mô hình cần padding và vì sao các cửa sổ convolution phải được kiểm tra trên từng mẫu.

Các kiểm tra đã hoàn thành. Hồ sơ audit xác nhận ID duy nhất, nhãn nhị phân, alphabet gồm 20 amino acid chuẩn, không thiếu trường, chiều dài khớp chuỗi, không có chuỗi trùng hoàn toàn và không có giao train/test theo chuỗi giống hệt. Những kiểm tra này ngăn các lỗi dữ liệu đơn giản trước khi fit mô hình.

Trường hợp biên có ảnh hưởng thật. Mẫu test âm sgh_sequence7831 dài 35 vẫn được giữ nguyên, dù một mô tả trong tài liệu nguồn ghi nhỏ hơn 35. Padding vì vậy dùng chiều dài 35. Dự đoán mọi mẫu test là other đã đạt khoảng 95,66% accuracy nhưng recall dương bằng 0; do đó accuracy đơn lẻ dễ gây hiểu nhầm. Chiều dài cũng không được dùng để tự gán lớp MHC.

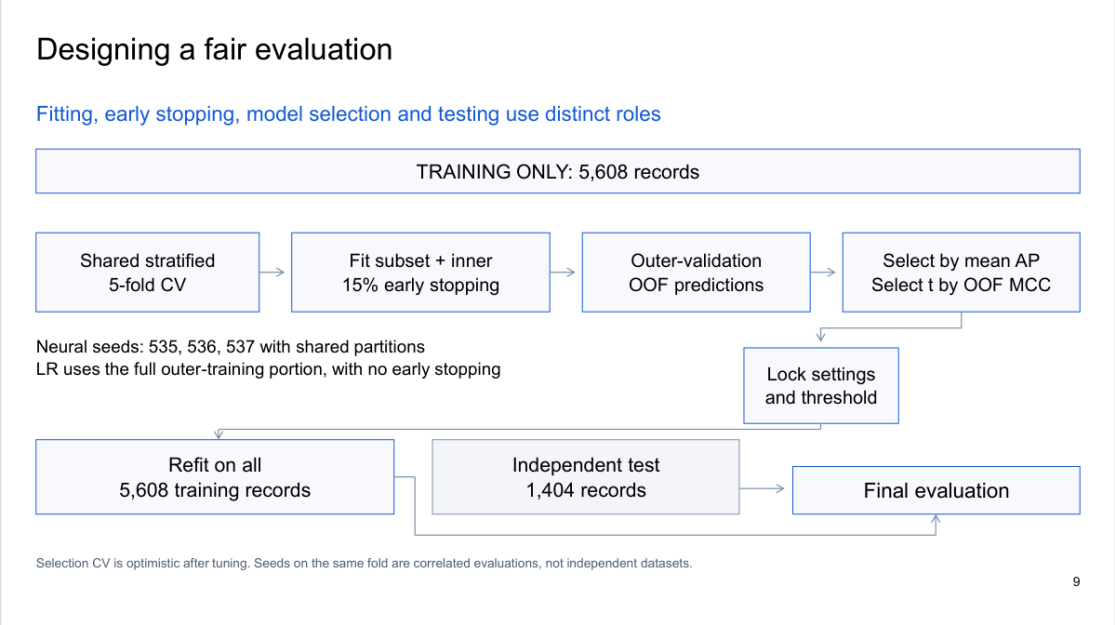
> **Ý cần nắm:** Audit không chỉ để báo cáo số liệu sạch: nó đã quyết định chiều dài padding và cách chọn metric.

Minh chứng: [S2], [S4], [S10]. Hình đối chiếu: slide 8 của PDF v3.

SLIDE 09

Vai trò khác nhau của fitting, early stopping, OOF và test

Designing a fair evaluation



Các lớp phân chia. Chỉ 5.608 mẫu train tham gia stratified 5-fold CV. Trong mỗi fold, phần outer-training của mô hình neural tách thêm 15% để early stopping; phần còn lại dùng tối ưu trọng số. Outer-validation chỉ tạo dự đoán sau quá trình fitting. LR không cần early stopping nên dùng toàn bộ outer-training.

OOF được hình thành thế nào?. Mỗi bản ghi train thuộc outer-validation đúng một lần. Ghép các dự đoán này tạo tập out-of-fold (OOF): ở dự đoán tương ứng, mô hình không fit bằng chính bản ghi đó. Các seed neural 535, 536 và 537 dùng chung phân chia; điểm số được trung bình theo bản ghi khi chọn ngưỡng.

Những quyết định dùng nguồn nào?. Cấu hình được chọn theo mean CV AP; ngưỡng theo OOF MCC. Sau khi khóa các lựa chọn, mô hình refit trên toàn bộ train rồi mới đánh giá test. Tuy vậy, CV cũng đã được dùng để tuning nên không phải ước lượng hậu chọn mô hình không chệch. Giao thức có inner early stopping, nhưng không phải nested CV cho toàn bộ quá trình chọn hyperparameter.

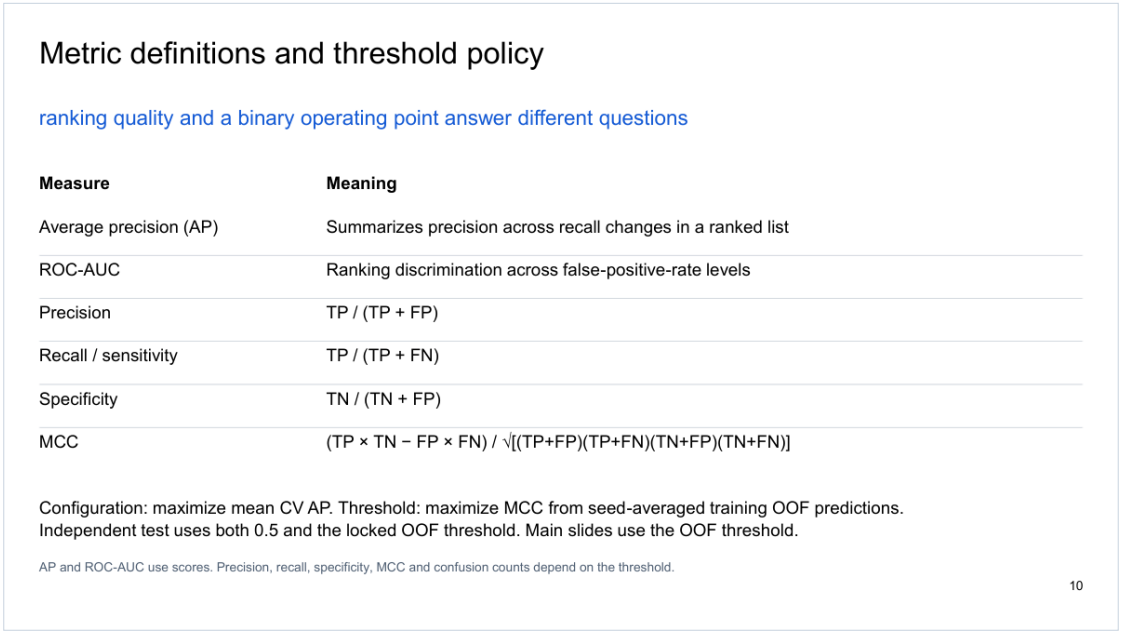
> **Ý cần nắm:** Không có đường từ test quay về tuning, early stopping hoặc chọn ngưỡng trong phép đánh giá này.

Minh chứng: [S2], [S3], [S5]. Hình đối chiếu: slide 9 của PDF v3.

SLIDE 10

Metric đo điều gì và vì sao ngưỡng phải được báo cáo?

Metric definitions and threshold policy



Metric definitions and threshold policy

ranking quality and a binary operating point answer different questions

Measure	Meaning
Average precision (AP)	Summarizes precision across recall changes in a ranked list
ROC-AUC	Ranking discrimination across false-positive-rate levels
Precision	TP / (TP + FP)
Recall / sensitivity	TP / (TP + FN)
Specificity	TN / (TN + FP)
MCC	(TP × TN − FP × FN) / √[(TP+FP)(TP+FN)(TN+FP)(TN+FN)]

Configuration: maximize mean CV AP. Threshold: maximize MCC from seed-averaged training OOF predictions. Independent test uses both 0.5 and the locked OOF threshold. Main slides use the OOF threshold.

AP and ROC-AUC use scores. Precision, recall, specificity, MCC and confusion counts depend on the threshold.

10

Metric của xếp hạng. Average precision (AP) tóm tắt precision tại các mức recall của danh sách xếp theo điểm. Giá trị trong dự án dùng average_precision_score, không phải diện tích PR tính bằng quy tắc hình thang. ROC-AUC mô tả khả năng phân biệt thứ hạng dương/âm qua các mức false-positive rate. Cả hai không thay đổi khi chỉ đổi ngưỡng nhị phân.

Metric tại một điểm vận hành. Precision = TP/(TP+FP) cho biết trong các dự đoán dương có bao nhiêu đúng. Recall = TP/(TP+FN) cho biết tìm được bao nhiêu mẫu dương thật. Specificity = TN/(TN+FP) cho biết nhận diện đúng nhóm âm. MCC kết hợp cả bốn ô của confusion matrix, hữu ích khi lớp mất cân bằng.

Chọn ngưỡng không phải hiệu chuẩn xác suất. Ngưỡng tối đa OOF MCC là một lựa chọn vận hành dựa trên train, không phải bằng chứng điểm số đã được calibration. Kết quả test có cả policy 0.5 và OOF-selected; các slide chính dùng OOF-selected. Ngưỡng tốt trên OOF vẫn có thể giảm MCC trên test, như đã xảy ra với composition LR.

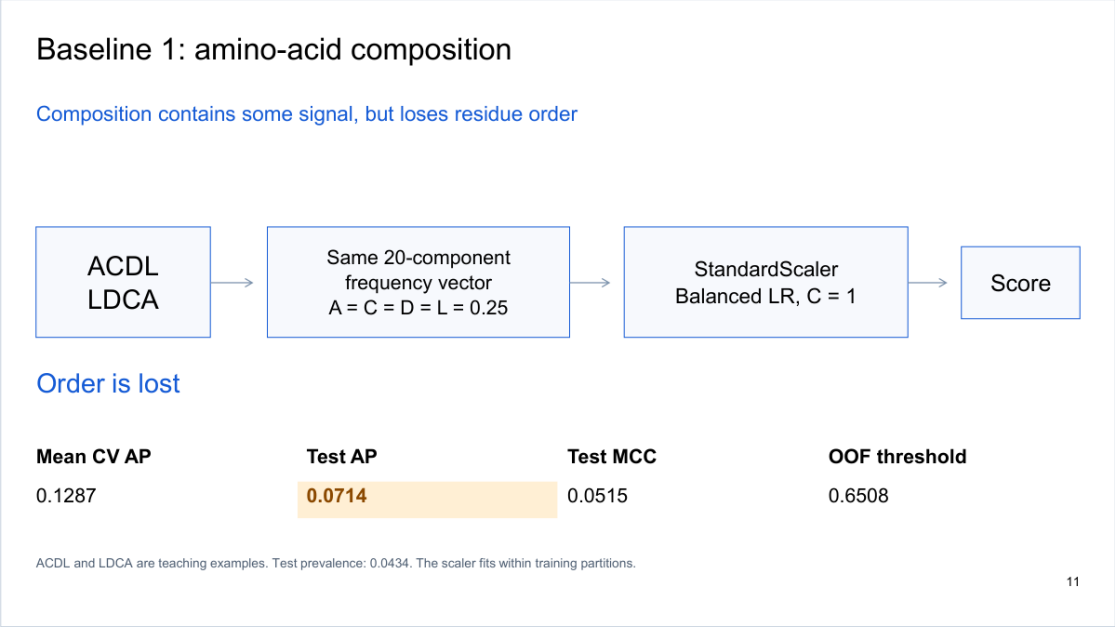
> **Ý cần nắm:** Khi đọc một số, cần xác định nó đo xếp hạng hay quyết định sau ngưỡng.

Minh chứng: [S2], [S3], [S5]. Hình đối chiếu: slide 10 của PDF v3.

SLIDE 11

Baseline composition: điều gì bị mất khi chỉ đếm amino acid?

Baseline 1: amino-acid composition



Cách biểu diễn. Mỗi peptide được chuyển thành 20 tần suất đã chuẩn hóa theo chiều dài. ACDL và LDCA là hai ví dụ giảng giải có cùng thành phần, nên trở thành cùng một vector dù thứ tự khác nhau. Đây không phải hai bản ghi thực nghiệm trong bộ dữ liệu.

Cách fit và lựa chọn. Vector đi qua StandardScaler và Logistic Regression với trọng số lớp balanced. Scaler được fit trong partition train tương ứng. C được khảo sát ở 0.1, 1 và 10; C=1 được chọn. C điều khiển nghịch đảo mức regularization: C nhỏ hơn tạo ràng buộc mạnh hơn lên hệ số.

Kết quả nói được gì?. Mean CV AP là 0.1287, nhưng test AP chỉ 0.0714, so với tỷ lệ dương test khoảng 0.0434. Test MCC là 0.0515 ở ngưỡng 0.6508. Thành phần có một phần tín hiệu, nhưng chưa đủ cho một bộ phân loại mạnh trên dữ liệu này. Điều đó chưa chứng minh thứ tự là nguyên nhân duy nhất của mọi cải thiện sau này, vì baseline tiếp theo còn đổi kiến trúc.

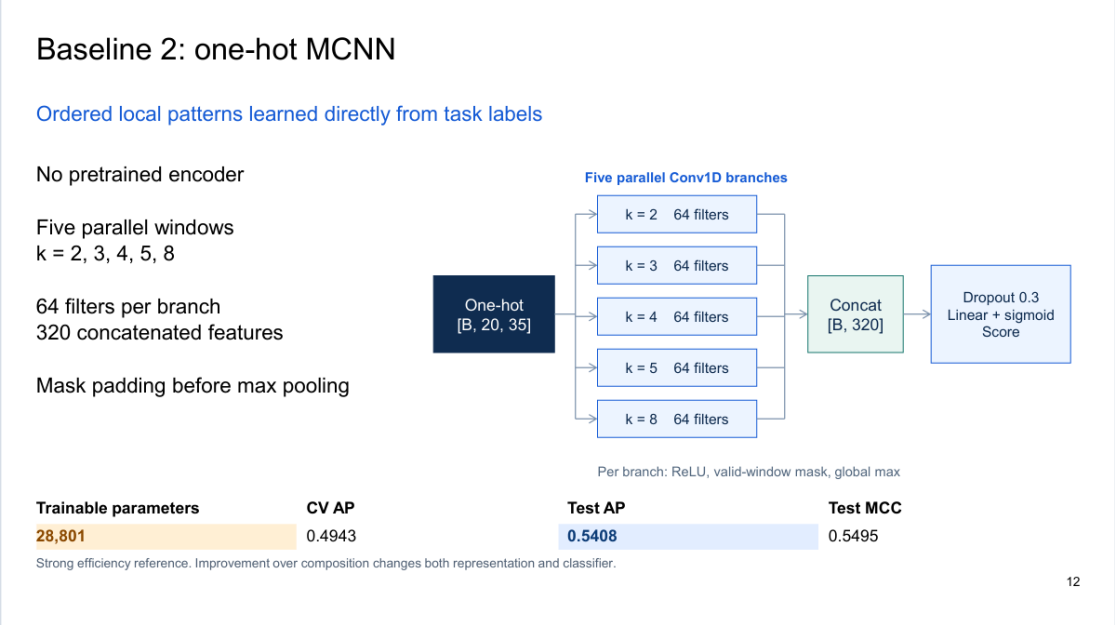
> **Ý cần nắm:** Baseline đơn giản cho biết mức tín hiệu có thể khai thác chỉ từ thành phần và làm mốc cho các mô hình phức tạp.

Minh chứng: [S3], [S5]. Hình đối chiếu: slide 11 của PDF v3.

SLIDE 12

One-hot MCNN: học mẫu cục bộ trực tiếp từ nhãn

Baseline 2: one-hot MCNN



Luồng xử lý. Sơ đồ I đọc từ trái sang phải. Mỗi amino acid được mã hóa one-hot 20 chiều; sau padding, [B,35,20] chuyển thành [B,20,35] để Conv1D quét theo vị trí. Đầu vào tách thành năm nhánh song song k=2,3,4,5,8, mỗi nhánh 64 filter. Các nhánh cùng nhận một đầu vào, không nối tiếp nhau.

Vì sao cần mask?. Sau Conv1D và ReLU, cửa sổ chạm padding bị loại trước global max. Mỗi nhánh giữ 64 giá trị; khối Concat ghép thành [B,320], tức 5 x 64 đặc trưng cho mỗi peptide. Dropout 0.3 và linear tạo một logit; sigmoid chuyển thành score khi suy luận. Dòng chú thích dưới sơ đồ áp dụng cho từng nhánh. Mô hình không dùng encoder pretrained.

Kết quả và vị trí của baseline. Mô hình có 28.801 tham số trainable, CV AP 0.4943, test AP 0.5408 và MCC 0.5495. Đây là mốc hiệu quả chi phí quan trọng. Sơ đồ mô tả đường đi của dữ liệu và phép ghép đặc trưng; các kết quả trong bảng là số đo thực nghiệm, không được suy ra từ hình minh họa.

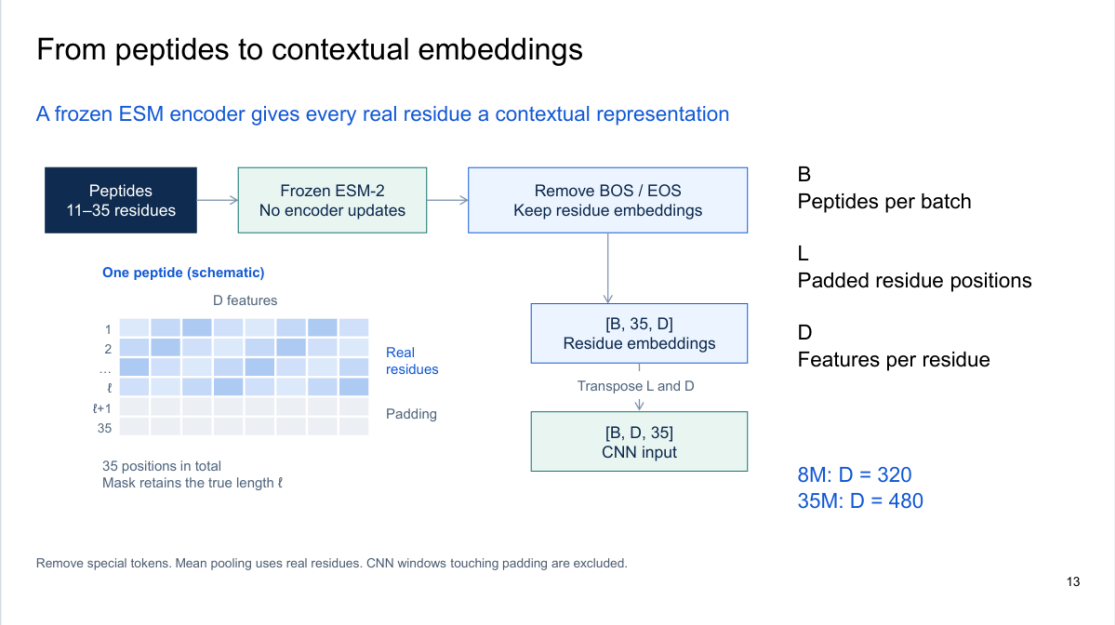
> **Ý cần nắm:** One-hot MCNN cho thấy học các mẫu có thứ tự từ nhãn đã tạo một baseline mạnh với chi phí thấp.

Minh chứng: [S3], [S5], [S13]. Hình đối chiếu: slide 12 của PDF v3.

SLIDE 13

ESM embeddings và ý nghĩa chính xác của B, L, D

From peptides to contextual embeddings



Khác biệt với one-hot. One-hot chỉ mã hóa danh tính ký tự tại vị trí. ESM đã học từ các chuỗi protein và tạo vector phụ thuộc ngữ cảnh; cùng một amino acid có thể nhận vector khác khi các ký tự xung quanh khác. Trong dự án, ESM bị đóng băng nên nhãn bài toán không cập nhật trọng số encoder.

Cách đọc tensor. Sơ đồ C bắt đầu từ peptide, qua frozen ESM-2 rồi bỏ BOS/EOS để giữ embedding của residue. B là số peptide trong batch, L=35 là số vị trí sau padding, D là số đặc trưng mỗi residue: 320 với 8M và 480 với 35M. Tensor [B,35,D] chuyển thành [B,D,35] cho CNN; transpose chỉ đổi trục, không tạo thêm thông tin.

Xử lý vị trí thực và padding. Ma trận phía dưới minh họa một peptide: các hàng xanh là residue thật, các hàng xám từ vị trí ℓ+1 đến 35 là padding; ℓ là chiều dài thật. Màu sắc chỉ để giải thích cấu trúc, không phải embedding đo được. Mean pooling chỉ lấy residue thật; convolution loại cửa sổ chạm padding trước global max. D là chiều embedding, không phải số filter CNN.

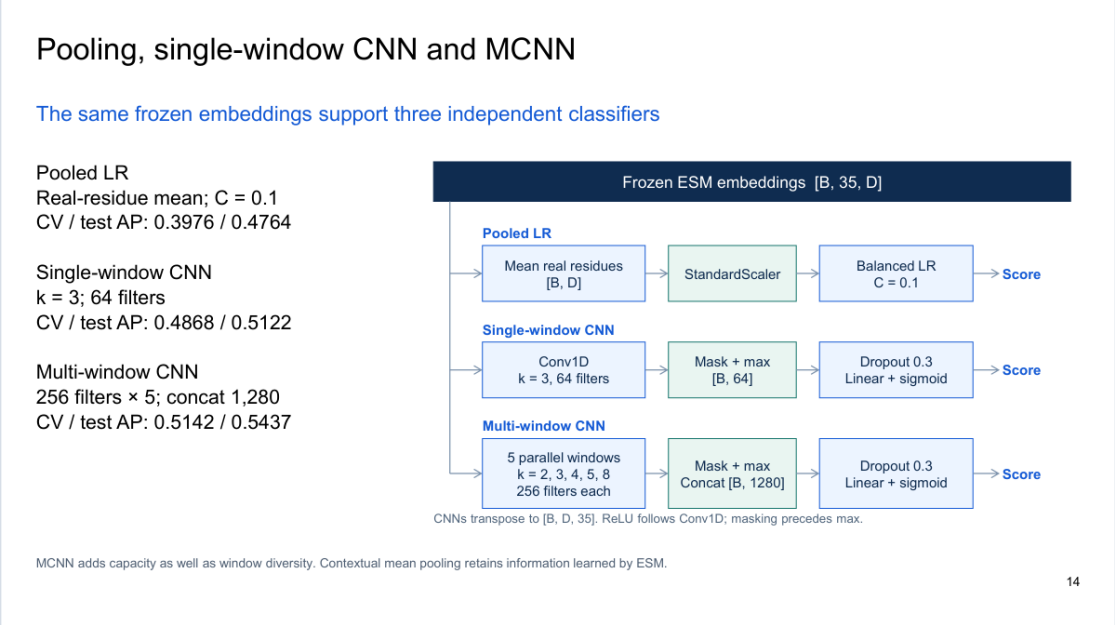
> **Ý cần nắm:** Encoder đóng băng cung cấp biểu diễn ngữ cảnh; phần được học cho bài toán nằm ở classifier phía sau.

Minh chứng: [S2], [S3], [S11], [S13]. Hình đối chiếu: slide 13 của PDF v3.

SLIDE 14

Cùng một embedding, ba cách khai thác thông tin

Pooling, single-window CNN and MCNN



Pooling và local extraction. Sơ đồ D có ba hàng độc lập cùng nhận frozen ESM embeddings, không phải ba bước nối tiếp. Pooled LR lấy mean trên residue thật, qua StandardScaler rồi balanced LR với C=0.1. Vì ESM đã dùng ngữ cảnh, mean pooling các embedding này không đồng nghĩa với việc chưa từng dùng thứ tự chuỗi.

MCNN được chọn. Single CNN chọn k=3, 64 filter, tạo [B,64] sau mask và global max. MCNN dùng năm cửa sổ song song k=2,3,4,5,8, mỗi nhánh 256 filter, ghép thành [B,1280]. Cả hai dùng ReLU sau Conv1D, rồi dropout 0.3, linear và sigmoid khi suy luận. Concat 1.280 khác với D=320 của ESM 8M và concat 320 của one-hot MCNN.

Quan sát định lượng. Với 8M, CV AP pooled/single/multi lần lượt là 0.3976/0.4868/0.5142; test AP là 0.4764/0.5122/0.5437. Local extraction hữu ích ở so sánh này. Lợi ích MCNN chưa thể quy hoàn toàn cho nhiều thang cửa sổ vì capacity cũng tăng. Sơ đồ giải thích kiến trúc, không chứng minh các filter đã học được motif sinh học.

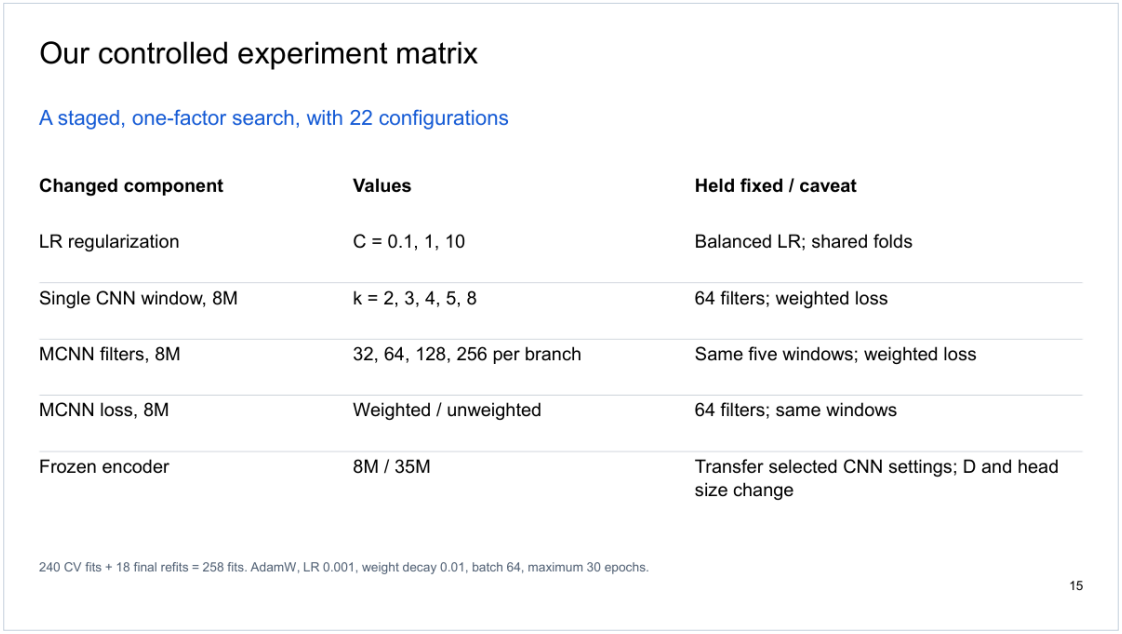
> **Ý cần nắm:** Kiến trúc phía sau có thể quan trọng ngang với chất lượng embedding, nhưng phải tách lợi ích biểu diễn khỏi capacity.

Minh chứng: [S2], [S3], [S5], [S13]. Hình đối chiếu: slide 14 của PDF v3.

SLIDE 15

Ma trận thí nghiệm được tổ chức theo từng yếu tố

Our controlled experiment matrix



Our controlled experiment matrix

A staged, one-factor search, with 22 configurations

Changed component	Values	Held fixed / caveat
LR regularization	C = 0.1, 1, 10	Balanced LR; shared folds
Single CNN window, 8M	k = 2, 3, 4, 5, 8	64 filters; weighted loss
MCNN filters, 8M	32, 64, 128, 256 per branch	Same five windows; weighted loss
MCNN loss, 8M	Weighted / unweighted	64 filters; same windows
Frozen encoder	8M / 35M	Transfer selected CNN settings; D and head size change

240 CV fits + 18 final refits = 258 fits. AdamW, LR 0.001, weight decay 0.01, batch 64, maximum 30 epochs.

15

Các trục đã khảo sát. LR thử C=0.1,1,10. Single CNN 8M thử cửa sổ 2,3,4,5,8 với 64 filter. MCNN 8M thử 32,64,128,256 filter mỗi nhánh ở cùng bộ cửa sổ. Weighted và unweighted loss được đối chiếu tại 64 filter. Các CNN 35M nhận lại cấu hình CNN đã chọn từ 8M, không mở một vòng tuning 35M mới.

Vì sao không gọi là full factorial?. Dự án không thử mọi tổ hợp của encoder, cửa sổ, filter, loss và optimizer. Đây là staged search với những so sánh một yếu tố được định nghĩa trước. AdamW giữ learning rate 0.001, weight decay 0.01, batch 64, dropout 0.3 và tối đa 30 epoch cho neural classifier.

Khối lượng thực hiện. Chín cấu hình LR x 5 fold tạo 45 CV fit. Mười ba cấu hình neural x 5 fold x 3 seed tạo 195 CV fit. Ba LR refit và 15 neural refit bổ sung 18, tổng cộng 258. Early stopping giảm số epoch, không giảm số fit cần có. Đây là số lần học mô hình, không phải 258 bộ dữ liệu độc lập.

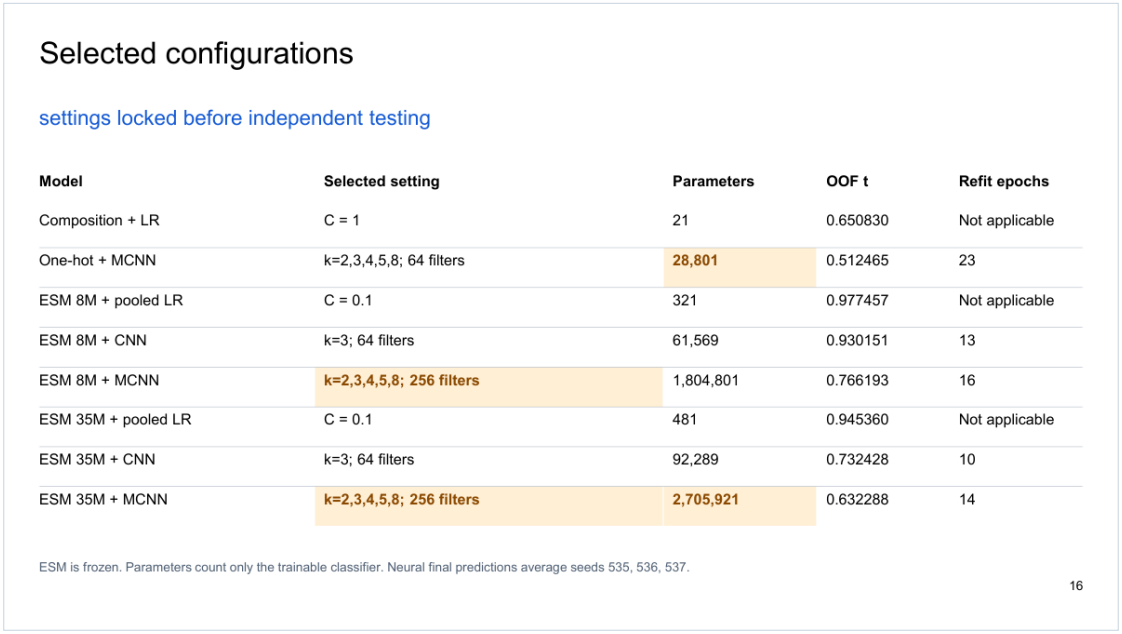
> **Ý cần nắm:** Ma trận cho phép truy nguyên ảnh hưởng của từng thay đổi trong phạm vi đã thử, thay vì ngầm khẳng định đã tìm mọi cấu hình.

Minh chứng: [S2], [S3], [S12]. Hình đối chiếu: slide 15 của PDF v3.

SLIDE 16

Các cấu hình đã khóa trước test

Selected configurations



Selected configurations

settings locked before independent testing

Model	Selected setting	Parameters	OOF t	Refit epochs
Composition + LR	C = 1	21	0.650830	Not applicable
One-hot + MCNN	k=2,3,4,5,8; 64 filters	28,801	0.512465	23
ESM 8M + pooled LR	C = 0.1	321	0.977457	Not applicable
ESM 8M + CNN	k=3; 64 filters	61,569	0.930151	13
ESM 8M + MCNN	k=2,3,4,5,8; 256 filters	1,804,801	0.766193	16
ESM 35M + pooled LR	C = 0.1	481	0.945360	Not applicable
ESM 35M + CNN	k=3; 64 filters	92,289	0.732428	10
ESM 35M + MCNN	k=2,3,4,5,8; 256 filters	2,705,921	0.632288	14

ESM is frozen. Parameters count only the trainable classifier. Neural final predictions average seeds 535, 536, 537.

16

Bảng này ghi lại quyết định nào?. Mỗi hàng là lựa chọn cuối cho một họ mô hình, kèm số tham số classifier, ngưỡng OOF và số epoch refit. LR chọn C=1 cho composition và C=0.1 cho hai pooled ESM. Single CNN dùng k=3, 64 filter; ESM MCNN dùng 256 filter trên mỗi nhánh.

Refit được xác định ra sao?. Neural refit trên toàn bộ 5.608 mẫu train với số epoch bằng trần của median best epoch trong CV. One-hot MCNN dùng 23 epoch; 8M CNN/MCNN dùng 13/16; 35M CNN/MCNN dùng 10/14. Không dùng test để quyết định dừng. Mỗi neural cấu hình cuối có ba seed refit.

Cách hiểu tham số và ngưỡng. 28.801 tham số của one-hot là mốc chi phí thấp. Head ESM 35M MCNN có 2.705.921 tham số trainable, ngoài encoder đóng băng. Số tham số lớn nhất không mang nghĩa tốt nhất. Ngưỡng khác nhau phản ánh phân bố score và tiêu chí OOF MCC; ngưỡng 0.9775 của pooled 8M không phải yêu cầu “97,75% chắc chắn” về sinh học.

> **Ý cần nắm:** Bảng lựa chọn khóa là cầu nối giữa tuning và test, giúp kiểm tra kết quả cuối có dùng đúng mô hình đã chọn hay không.

Minh chứng: [S3], [S5], [S12]. Hình đối chiếu: slide 16 của PDF v3.

SLIDE 17

Results: đánh giá quan sát cùng độ ổn định và chi phí

Results



Vai trò của phần kết quả. Trang chuyển phần đánh dấu lúc các lựa chọn phương pháp được đối chiếu với dữ liệu thực nghiệm. Trình tự tiếp theo đi từ learning curves đến CV, ablation, chi phí encoder, test độc lập, khoảng bất định và confusion matrices.

Cách đặt câu hỏi khi đọc. Một điểm AP cao hơn cần được đọc cùng với partition, spread, số tham số và ngưỡng. Thứ hạng theo AP có thể khác thứ hạng theo precision hoặc recall. Phần này cũng phân biệt kết quả dùng để lựa chọn trong CV với phép kiểm tra cuối trên test.

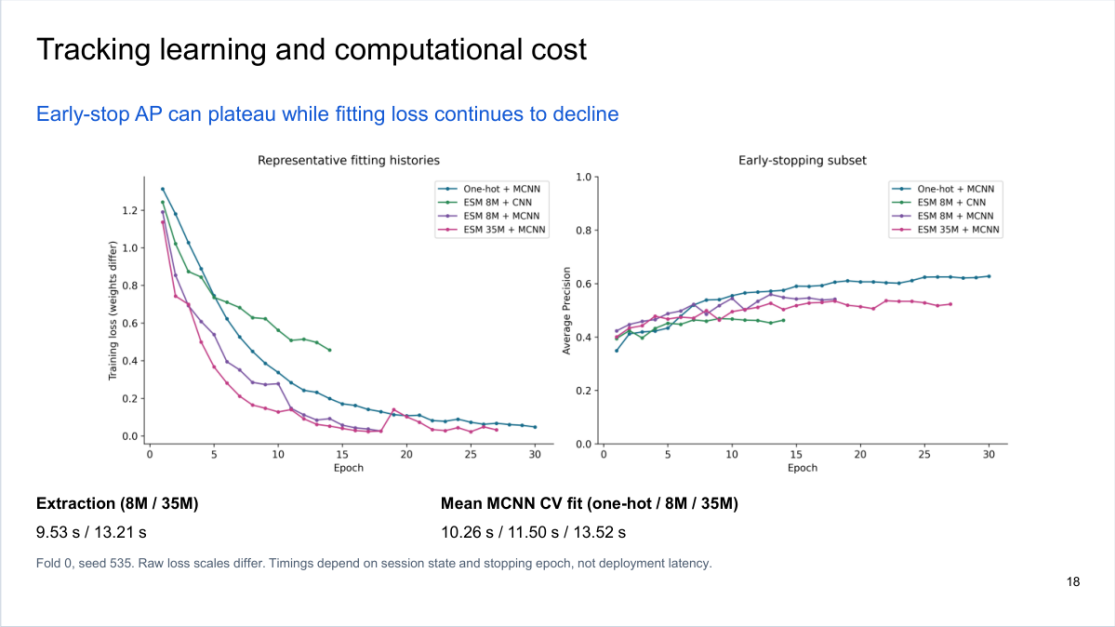
> **Ý cần nắm:** Kết quả là một tập bằng chứng có điều kiện, không phải một bảng xếp hạng duy nhất.

Minh chứng: [S1], [S2]. Hình đối chiếu: slide 17 của PDF v3.

SLIDE 18

Learning curves cho biết mô hình đã học và dừng thế nào?

Tracking learning and computational cost



Hai đại lượng khác nhau. Đường loss bên trái mô tả mức phù hợp với tập fitting khi tối ưu. AP bên phải được đo trên tập early stopping, dùng để chọn checkpoint trong fold. Loss có thể tiếp tục giảm trong khi AP chững lại hoặc dao động; vì vậy mô hình ở epoch cuối chưa chắc là checkpoint nên giữ.

Những gì thực sự được vẽ. Hình dùng các cấu hình được chọn ở fold 0, seed 535, không phải đường trung bình của mọi run. Nó minh họa hành vi học đã quan sát. Một vài run có best epoch chạm trần 30; điều này gợi ý một câu hỏi thí nghiệm tiếp theo chứ chưa chứng minh tăng epoch sẽ cải thiện test. Loss weighted và unweighted không thể so trực tiếp theo độ lớn.

Chi phí được tách thành hai phần. Trích xuất embedding mất 9.53 giây cho 8M và 13.21 giây cho 35M trong log đã ghi. Mean downstream CV fit của one-hot/8M MCNN/35M MCNN là 10.26/11.50/13.52 giây trên Tesla T4. Đây là đo đạc phụ thuộc phiên chạy và stopping epoch, không phải độ trễ triển khai cho một peptide.

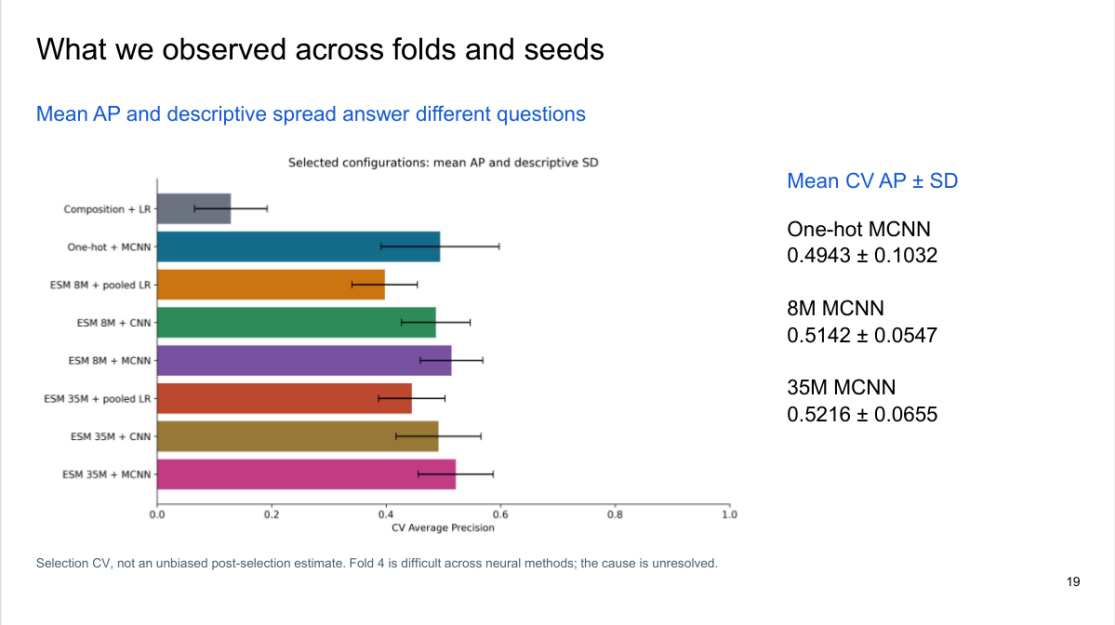
> **Ý cần nắm:** Learning history giải thích lựa chọn checkpoint; thời gian encoder và thời gian fit classifier phải được đọc riêng.

Minh chứng: [S2], [S6], [S7]. Hình đối chiếu: slide 18 của PDF v3.

SLIDE 19

Mean CV AP và độ phân tán mô tả

What we observed across folds and seeds



Đọc thanh ngang và error bar. Chiều dài thanh là mean AP của cấu hình được chọn. Error bar là sample SD trên các hàng fold/seed. Mean thể hiện mức điển hình trong phép tổng hợp này; SD mô tả mức phân tán, không phải khoảng tin cậy 95% hay xác suất mô hình tốt hơn.

Quan sát nổi bật. One-hot MCNN đạt 0.4943 với SD 0.1032. 8M MCNN đạt 0.5142 với SD 0.0547; 35M MCNN đạt 0.5216 với SD 0.0655. Theo cách tổng hợp này, one-hot có độ phân tán lớn hơn hai ESM MCNN. Điều đó không loại bỏ giá trị của baseline chi phí thấp, mà bổ sung một chiều đánh giá.

Giới hạn của điểm CV. Cùng các fold và các record được dùng lặp lại giữa seed, nên 15 hàng neural không tương đương 15 dataset độc lập. Các mean này còn tham gia tuning, vì vậy có tính lạc quan sau chọn cấu hình. Kết quả test ở phần sau mới là phép kiểm tra cuối của các lựa chọn đã khóa.

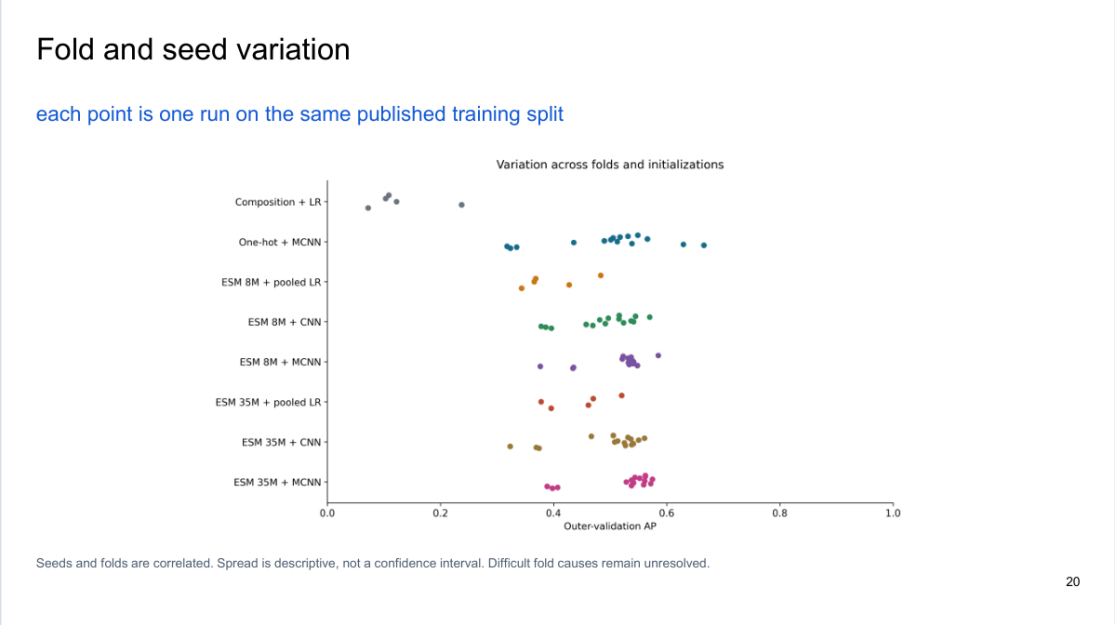
> **Ý cần nắm:** Mean và spread cần đi cùng nhau; error bar ở đây không đủ để tuyên bố khác biệt có ý nghĩa thống kê.

Minh chứng: [S2], [S5], [S7]. Hình đối chiếu: slide 19 của PDF v3.

SLIDE 20

Các điểm fold/seed bộc lộ điều gì mà mean che khuất?

Fold and seed variation



Ý nghĩa của mỗi điểm. Mỗi điểm là AP của một run trên outer-validation. Các điểm trải ngang cho biết cấu hình có thể cho kết quả khác nhau khi đổi fold hoặc khởi tạo. Chúng không phải các mẫu bệnh nhân độc lập và cũng không phải kết quả của những bộ test độc lập.

Dấu hiệu partition khó. Fold 4 có mean AP thấp ở nhiều mô hình neural: one-hot MCNN 0.3252, 8M MCNN 0.4153 và 35M MCNN 0.3978. Khi nhiều phương pháp cùng giảm trên một fold, partition có thể chứa những ví dụ khó hơn; đây là một quan sát đáng điều tra.

Điều chưa biết. Chưa có bằng chứng để kết luận nguyên nhân là chiều dài peptide, motif, lỗi nhãn hay similarity. Việc chọn một lời giải thích sinh học từ đồ thị này sẽ vượt quá dữ liệu. Muốn kiểm tra nguyên nhân cần phân tích partition và thiết kế thí nghiệm tiếp, tránh chỉnh mô hình theo các lỗi test đã thấy.

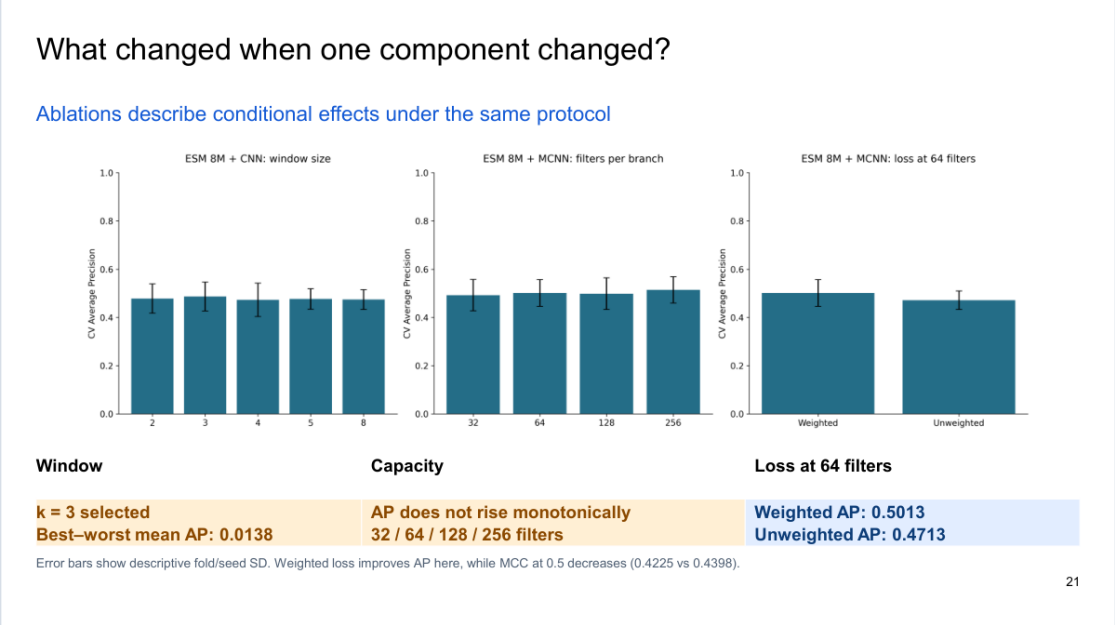
> **Ý cần nắm:** Đồ thị điểm giúp phân biệt tín hiệu trung bình với sự nhạy cảm theo partition và khởi tạo.

Minh chứng: [S2], [S7]. Hình đối chiếu: slide 20 của PDF v3.

SLIDE 21

Ablation: thay một yếu tố đã tạo ra thay đổi nào?

What changed when one component changed?



Cửa sổ và filter. Trong single CNN 8M, k=3 có mean AP cao nhất 0.4868, nhưng khoảng giữa mean tốt nhất và thấp nhất chỉ 0.0138. MCNN tăng filter 32/64/128/256 cho AP 0.4922/0.5013/0.4985/0.5142. Xu hướng không đơn điệu: 128 filter không tốt hơn 64 ở mean quan sát.

Loss với kiến trúc cố định. Weighted BCE tăng trọng số mẫu dương theo tỷ lệ âm/dương của tập fitting để lớp hiếm có ảnh hưởng lớn hơn lên loss; unweighted dùng trọng số 1. Tại 64 filter và cùng các cửa sổ, weighted loss đạt AP 0.5013 so với 0.4713, tăng 0.0300. Tuy nhiên MCC ở ngưỡng 0.5 là 0.4225 so với 0.4398. Weighting giúp xếp hạng ở đây, nhưng không cải thiện mọi metric.

Cách diễn giải hợp lệ. Các cột màu thể hiện những đối chiếu có điều kiện được giữ cố định, không khẳng định cửa sổ 3 là độ dài motif phổ quát hoặc càng nhiều filter càng tốt. Error bar vẫn là SD mô tả. Kết quả CV phục vụ chọn cấu hình; chưa có test nào được dùng để chọn lại loss.

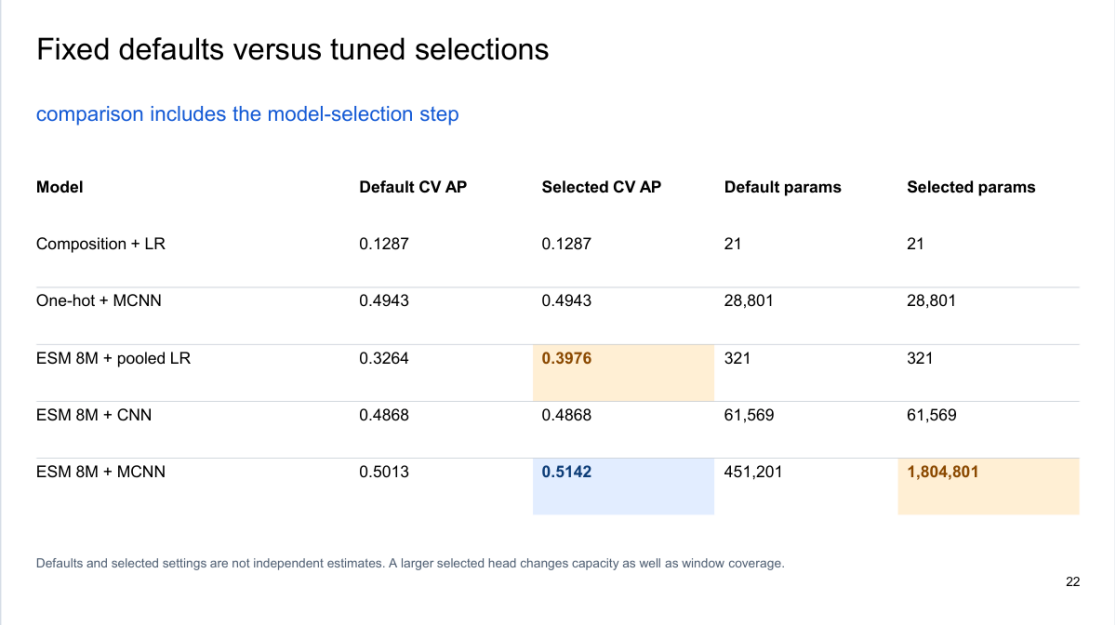
> **Ý cần nắm:** Ablation hữu ích nhất khi ghi rõ yếu tố đã đổi, yếu tố giữ nguyên và metric nào thực sự cải thiện.

Minh chứng: [S2], [S3], [S12]. Hình đối chiếu: slide 21 của PDF v3.

SLIDE 22

Tách hiệu ứng biểu diễn khỏi lợi ích của tuning

Fixed defaults versus tuned selections



Fixed defaults versus tuned selections

comparison includes the model-selection step

Model	Default CV AP	Selected CV AP	Default params	Selected params
Composition + LR	0.1287	0.1287	21	21
One-hot + MCNN	0.4943	0.4943	28,801	28,801
ESM 8M + pooled LR	0.3264	0.3976	321	321
ESM 8M + CNN	0.4868	0.4868	61,569	61,569
ESM 8M + MCNN	0.5013	0.5142	451,201	1,804,801

Defaults and selected settings are not independent estimates. A larger selected head changes capacity as well as window coverage.

22

Vì sao có hai cột default và selected?. Fixed defaults là các thiết lập tham chiếu trước lựa chọn, còn selected là cấu hình thắng theo CV. So sánh chúng cho biết tuning đã đóng góp bao nhiêu trong từng họ. Không nên dùng một mô hình đã tune để so với baseline mặc định rồi quy toàn bộ chênh lệch cho pretrained representation.

Hai thay đổi cần chú ý. Pooled 8M LR từ C=1 sang C=0.1 tăng CV AP từ 0.3264 lên 0.3976 mà vẫn có 321 tham số classifier. ESM 8M MCNN từ 64 lên 256 filter tăng AP từ 0.5013 lên 0.5142, đồng thời tham số tăng từ 451.201 lên 1.804.801.

Đối chiếu one-hot công bằng hơn. Tại MCNN 64 filter, one-hot AP là 0.4943 và ESM 8M là 0.5013, chênh 0.0070. Đối chiếu đó gần với câu hỏi về representation hơn so với ESM đã tune, nhưng vẫn chưa khớp parameter count vì số kênh đầu vào khác. Muốn tách capacity triệt để hơn cần thí nghiệm parameter-matched mới.

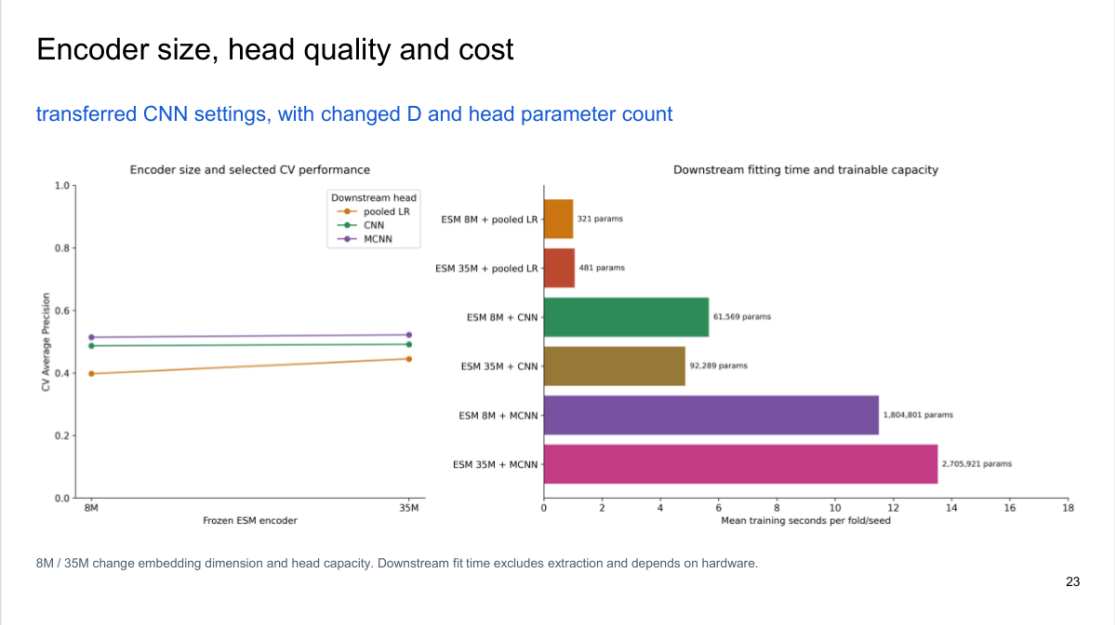
> **Ý cần nắm:** Một phần cải thiện đến từ regularization hoặc head lớn hơn, không chỉ từ việc dùng ESM.

Minh chứng: [S2], [S3], [S12]. Hình đối chiếu: slide 22 của PDF v3.

SLIDE 23

Encoder lớn hơn có lợi nhất quán không?

Encoder size, head quality and cost



Cách đọc hình. Bên trái là CV AP theo encoder 8M/35M cho ba loại head. Bên phải là thời gian fit downstream và số tham số head. Kích thước encoder là số tham số pretrained bị đóng băng; trainable parameters trên thanh chỉ thuộc classifier được học từ nhãn.

Kết quả phụ thuộc head. Pooled CV AP tăng 0.3976 lên 0.4449 nhưng test AP giảm 0.4764 xuống 0.3614. Single CNN CV tăng 0.4868 lên 0.4913 nhưng test giảm 0.5122 xuống 0.4870. Chỉ MCNN tăng cả CV AP 0.5142 lên 0.5216 và test AP 0.5437 lên 0.5758 trong các lựa chọn này.

Chi phí và yếu tố đi kèm. Đổi 8M sang 35M cũng đổi D từ 320 sang 480, làm tăng head parameter count dù chuyển nguyên k và số filter. Tốc độ fit còn phụ thuộc early stopping, nên không nhất thiết tỷ lệ thuận với kích thước encoder. Không có cơ sở để suy ra mọi head đều hưởng lợi từ một encoder lớn hơn.

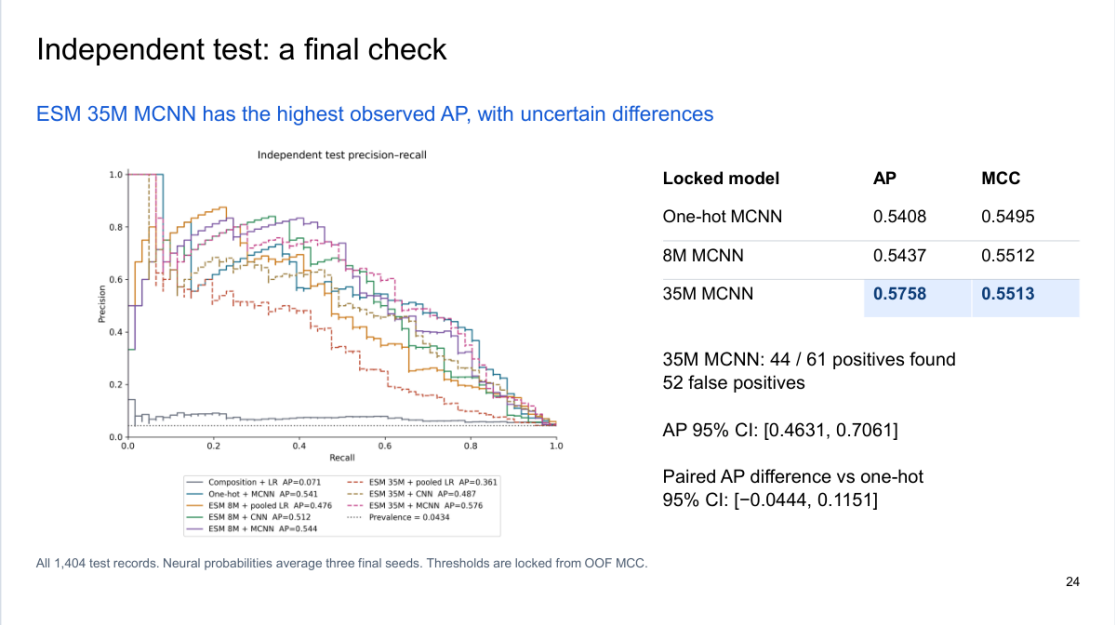
> **Ý cần nắm:** Kích thước encoder cần được đánh giá theo từng classifier, cùng chi phí và hiệu năng ngoài CV.

Minh chứng: [S2], [S5], [S6]. Hình đối chiếu: slide 23 của PDF v3.

SLIDE 24

Test độc lập kiểm tra những lựa chọn đã khóa

Independent test: a final check



Ranh giới của phép kiểm tra. Tất cả 1.404 mẫu test được dùng sau lựa chọn cấu hình và threshold trên train. Neural score là trung bình xác suất của ba seed refit. ESM 35M MCNN đã có CV AP cao nhất trước test, nên việc nó có test AP cao nhất không phải là lý do quay lại tuning.

Kết quả chính. AP test của one-hot, 8M MCNN và 35M MCNN lần lượt là 0.5408, 0.5437 và 0.5758. MCC tương ứng 0.5495, 0.5512 và 0.5513. 35M MCNN tìm được 44/61 dương nhưng có 52 false positive; các điểm số tổng hợp vì vậy cần được đọc cùng trade-off thực tế.

Độ chắc chắn của chênh lệch. AP 95% CI của 35M MCNN là [0.4631,0.7061]. Khoảng bootstrap paired cho chênh lệch AP so với one-hot là [-0.0444,0.1151], chứa 0. Điểm cao nhất quan sát được chưa chứng minh vượt trội đáng tin cậy. Việc chưa chứng minh khác biệt cũng không chứng minh hai mô hình tương đương.

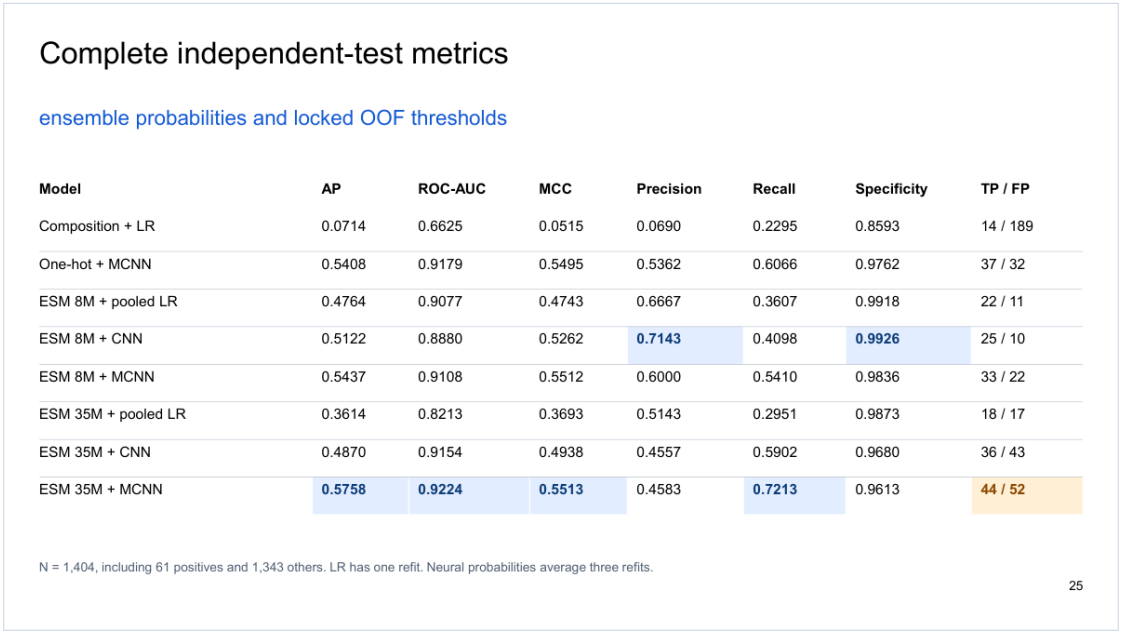
> **Ý cần nắm:** Test cung cấp phép kiểm tra cuối và mức bất định; không biến một chênh lệch nhỏ thành kết luận tuyệt đối.

Minh chứng: [S2], [S5], [S8]. Hình đối chiếu: slide 24 của PDF v3.

SLIDE 25

Đọc toàn bộ bảng test thay vì chỉ một cột tô xanh

Complete independent-test metrics



Complete independent-test metrics

ensemble probabilities and locked OOF thresholds

Model	AP	ROC-AUC	MCC	Precision	Recall	Specificity	TP / FP
Composition + LR	0.0714	0.6625	0.0515	0.0690	0.2295	0.8593	14 / 189
One-hot + MCNN	0.5408	0.9179	0.5495	0.5362	0.6066	0.9762	37 / 32
ESM 8M + pooled LR	0.4764	0.9077	0.4743	0.6667	0.3607	0.9918	22 / 11
ESM 8M + CNN	0.5122	0.8880	0.5262	0.7143	0.4098	0.9926	25 / 10
ESM 8M + MCNN	0.5437	0.9108	0.5512	0.6000	0.5410	0.9836	33 / 22
ESM 35M + pooled LR	0.3614	0.8213	0.3693	0.5143	0.2951	0.9873	18 / 17
ESM 35M + CNN	0.4870	0.9154	0.4938	0.4557	0.5902	0.9680	36 / 43
ESM 35M + MCNN	0.5758	0.9224	0.5513	0.4583	0.7213	0.9613	44 / 52

N = 1,404, including 61 positives and 1,343 others. LR has one refit. Neural probabilities average three refits.

25

Một mô hình có thể thắng theo metric này nhưng không theo metric khác. 35M MCNN có AP 0.5758, ROC-AUC 0.9224, MCC 0.5513 và recall 0.7213 cao nhất trong bảng. 8M single CNN lại có precision 0.7143 và specificity 0.9926 cao nhất. Hai lựa chọn thể hiện các ưu tiên vận hành khác nhau.

Đổi metric thành số trường hợp. 35M MCNN tìm 44 mẫu dương và báo nhầm 52 mẫu âm. One-hot tìm 37 và báo nhầm 32. 8M MCNN tìm 33 và báo nhầm 22. Single CNN 8M tìm 25 và báo nhầm 10. Vì chỉ có 61 dương, thêm vài trường hợp có thể thay đổi recall đáng kể.

Một phép tính minh họa. Với 35M MCNN, precision = 44/(44+52) = 0.4583 và recall = 44/61 = 0.7213. Không thể đọc recall 0.7213 thành “72% mọi dự đoán đều đúng”. Các ô xanh chỉ đánh dấu cực đại của từng metric trong bảng; chúng không là kiểm định thống kê hay tiêu chí lựa chọn lâm sàng.

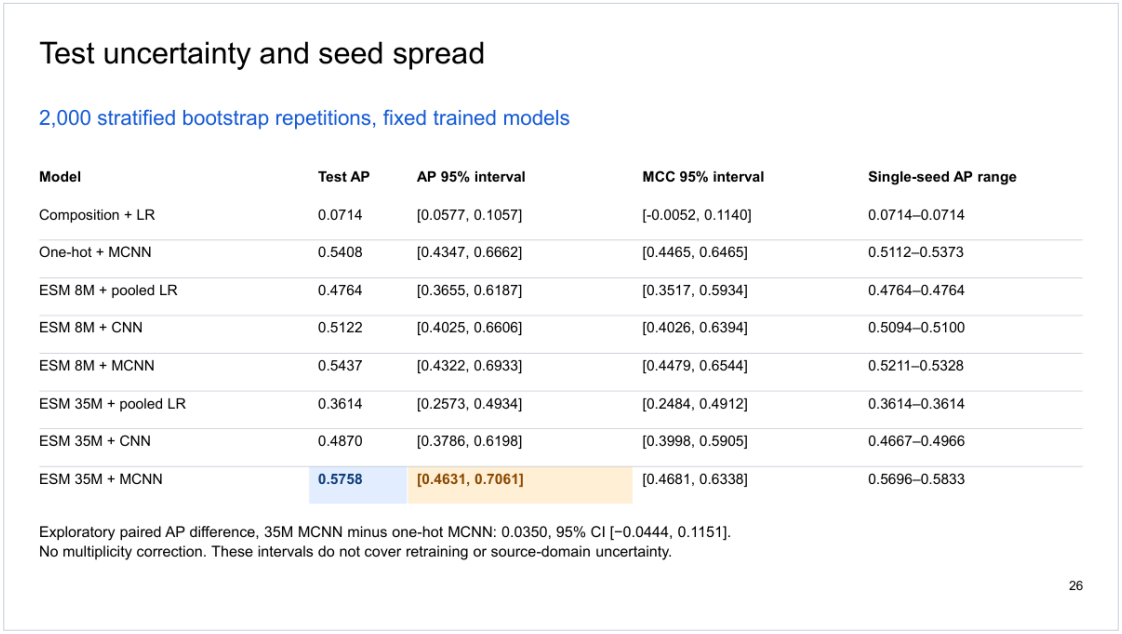
> **Ý cần nắm:** Sự lựa chọn giữa tìm nhiều dương hơn và giảm false positive phải được phát biểu rõ bằng metric cùng confusion counts.

Minh chứng: [S2], [S5]. Hình đối chiếu: slide 25 của PDF v3.

SLIDE 26

Phân biệt bootstrap uncertainty với seed variability

Test uncertainty and seed spread



Test uncertainty and seed spread

2,000 stratified bootstrap repetitions, fixed trained models

Model	Test AP	AP 95% interval	MCC 95% interval	Single-seed AP range
Composition + LR	0.0714	[0.0577, 0.1057]	[-0.0052, 0.1140]	0.0714–0.0714
One-hot + MCNN	0.5408	[0.4347, 0.6662]	[0.4465, 0.6465]	0.5112–0.5373
ESM 8M + pooled LR	0.4764	[0.3655, 0.6187]	[0.3517, 0.5934]	0.4764–0.4764
ESM 8M + CNN	0.5122	[0.4025, 0.6606]	[0.4026, 0.6394]	0.5094–0.5100
ESM 8M + MCNN	0.5437	[0.4322, 0.6933]	[0.4479, 0.6544]	0.5211–0.5328
ESM 35M + pooled LR	0.3614	[0.2573, 0.4934]	[0.2484, 0.4912]	0.3614–0.3614
ESM 35M + CNN	0.4870	[0.3786, 0.6198]	[0.3998, 0.5905]	0.4667–0.4966
ESM 35M + MCNN	0.5758	[0.4631, 0.7061]	[0.4681, 0.6338]	0.5696–0.5833

Exploratory paired AP difference, 35M MCNN minus one-hot MCNN: 0.0350, 95% CI [−0.0444, 0.1151].
No multiplicity correction. These intervals do not cover retraining or source-domain uncertainty.

26

Bootstrap test đo biến thiên nào?. Dự án dùng 2.000 lần lấy mẫu có hoàn lại, giữ riêng số dương 61 và âm 1.343 trong mỗi mẫu bootstrap. Các mô hình và ngưỡng đã fit không thay đổi. Percentile intervals mô tả mức nhạy của metric đối với lấy mẫu test dưới điều kiện đó.

Seed spread đo một nguồn khác. Khoảng AP single-seed cho biết đổi khởi tạo ở cùng protocol có thể tạo ra kết quả khác nhau. Ensemble lấy trung bình score theo từng peptide rồi mới tính AP, nên ensemble AP không phải trung bình ba AP riêng. Việc ensemble AP khác khoảng các AP seed không nhất thiết là lỗi.

Đọc chênh lệch trực tiếp. Paired bootstrap lấy cùng các ID được resample cho hai mô hình trong mỗi lần. Chênh AP 35M MCNN trừ one-hot có point estimate 0.0350, CI [-0.0444,0.1151]. Đây là phân tích thăm dò sau đánh giá, chưa điều chỉnh nhiều so sánh. Nó không bao gồm bất định từ retraining, thu thập dữ liệu hay nhãn.

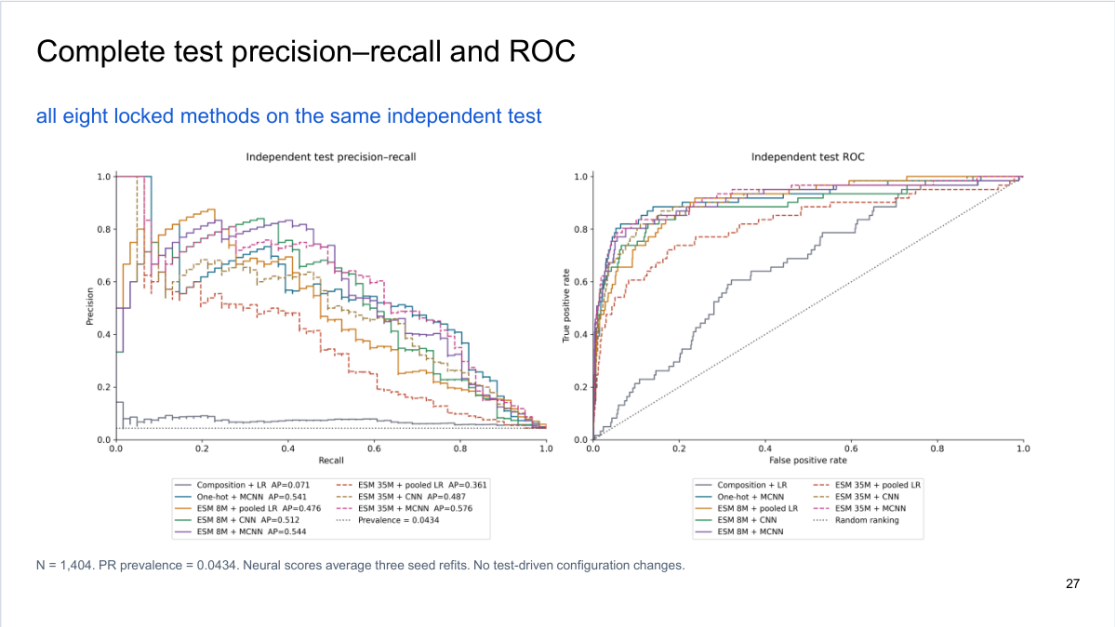
> **Ý cần nắm:** CI của metric, CI của chênh lệch paired và spread theo seed trả lời ba câu hỏi khác nhau.

Minh chứng: [S2], [S5], [S8]. Hình đối chiếu: slide 26 của PDF v3.

SLIDE 27

PR và ROC là hai góc nhìn của cùng bộ score

Complete test precision-recall and ROC



Đường precision-recall. Mỗi đường PR theo dõi precision khi hạ ngưỡng để thu thêm mẫu dương. Đường prevalence khoảng 0.0434 là mốc tham chiếu cho xếp hạng không có thông tin. AP tóm tắt chất lượng xếp hạng, nhưng hai đường vẫn có thể cắt nhau và đổi ưu thế ở vùng recall khác nhau.

Đường ROC. ROC đặt true-positive rate lên trục dọc và false-positive rate lên trục ngang. Trong bài toán nhiều âm, một false-positive rate nhỏ vẫn có thể tương ứng nhiều báo nhầm. Vì vậy ROC-AUC cao cần được đọc cùng PR và các số FP cụ thể, không dùng nó để thay thế precision.

Quan hệ với ngưỡng khóa. Hình quét nhiều ngưỡng để mô tả score, còn confusion matrix ở slide 28 chỉ dùng ngưỡng OOF đã khóa. Vẽ toàn bộ đường cong test không có nghĩa là được chọn lại ngưỡng đẹp nhất trên test. Không có thay đổi cấu hình hay threshold theo đường cong được thực hiện trong kết quả đang báo cáo.

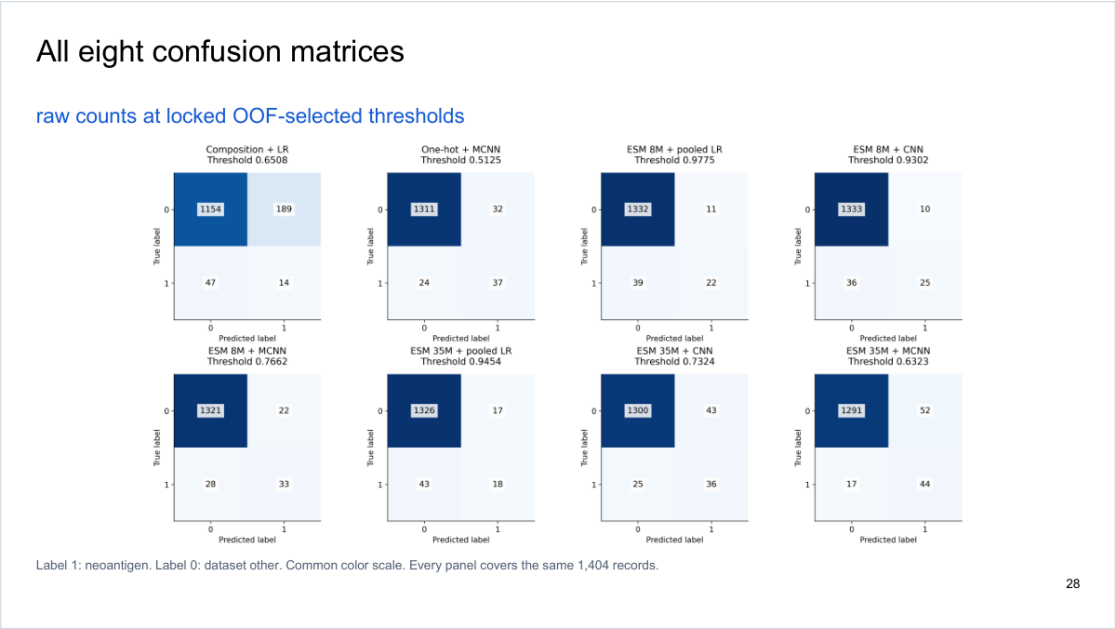
> **Ý cần nắm:** Đường cong mô tả khả năng đánh đổi của score; điểm vận hành được báo cáo vẫn phải theo policy đã khóa.

Minh chứng: [S2], [S5]. Hình đối chiếu: slide 27 của PDF v3.

SLIDE 28

Confusion matrices chuyển tỷ lệ thành số đếm kiểm tra được

All eight confusion matrices



Cách đọc một panel. Hàng là nhãn thật, cột là nhãn dự đoán. Ô trên trái là TN, trên phải FP, dưới trái FN và dưới phải TP. Mọi panel đều có 1.343 âm thật, 61 dương thật và dùng cùng thang màu, nên có thể đối chiếu số đếm trực tiếp giữa các mô hình.

Ví dụ 35M MCNN. Ma trận gồm TN=1.291, FP=52, FN=17, TP=44. Tổng 1.291+52+17+44 = 1.404, đồng thời TP+FN=61. Các tổng là kiểm tra nhất quán đơn giản nhưng cần thiết khi đưa metric từ nhiều file vào báo cáo.

Điều màu sắc có thể che khuất. TN rất lớn vì lớp âm áp đảo, nên màu đậm ở ô TN không tự chứng minh mô hình hữu ích cho tìm dương. Composition LR vẫn có 1.154 TN nhưng bỏ sót 47/61 dương và tạo 189 FP tại ngưỡng khóa. Nhìn các ô nhỏ và mẫu số dương quan trọng hơn chỉ nhìn vùng màu đậm nhất.

> **Ý cần nắm:** Confusion counts giúp kiểm tra metric và hiểu chính xác mô hình tìm đúng, bỏ sót và báo nhầm bao nhiêu mẫu.

Minh chứng: [S2], [S5]. Hình đối chiếu: slide 28 của PDF v3.

SLIDE 29

Conclusion: tổng hợp điều đã biết và phần còn mở

Conclusion



Vai trò của phần kết luận. Trang chuyển phần đưa trọng tâm từ bảng điểm sang mức độ hiểu được của nghiên cứu. Các slide tiếp theo xem ví dụ lỗi, provenance của run và các bài học có thể rút ra từ toàn bộ chuỗi thí nghiệm.

Tiêu chuẩn của một kết luận tốt. Kết luận cần đồng thời ghi nhận phần đã hoàn thành và điều chưa được chứng minh. Một score cao nhất có thể cùng tồn tại với khoảng bất định rộng, một baseline đơn giản có thể còn rất hữu ích, và một hồ sơ số liệu nhất quán vẫn có thể thiếu chính xác snapshot source đã chạy.

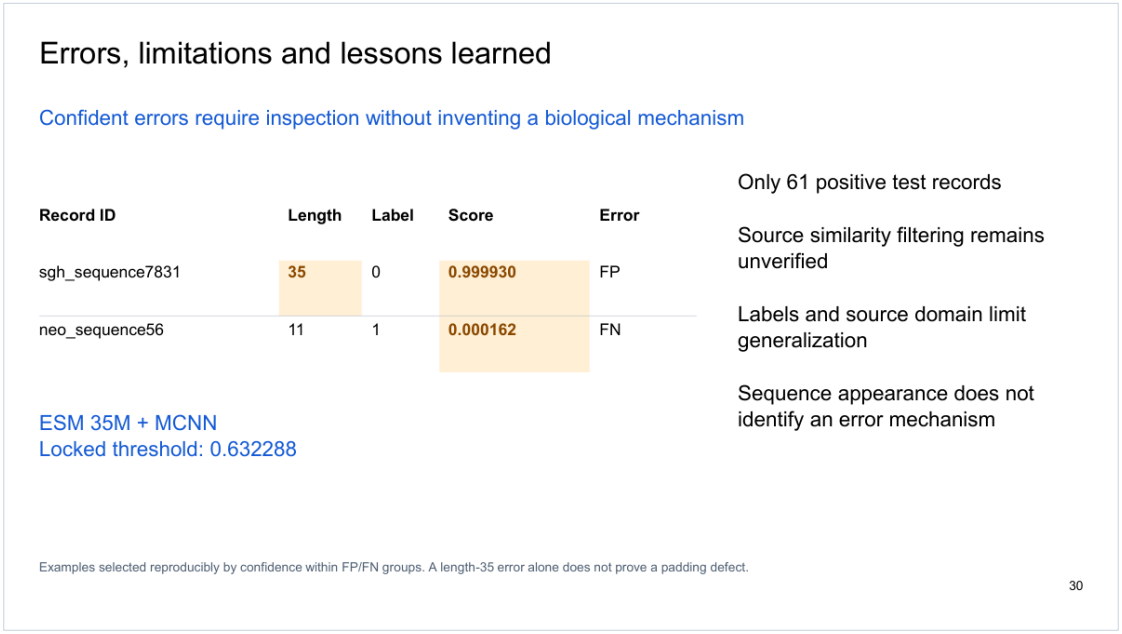
> **Ý cần nắm:** Độ tin cậy của báo cáo nằm ở việc nêu rõ cả kết quả tích cực lẫn giới hạn chứng cứ.

Minh chứng: [S1], [S2]. Hình đối chiếu: slide 29 của PDF v3.

SLIDE 30

Hai lỗi cụ thể có ý nghĩa gì?

Errors, limitations and lessons learned



Những bản ghi thật. Ở ngưỡng 0.632288 của 35M MCNN, mẫu other sgh_sequence7831 dài 35 có score 0.999930 nhưng là false positive. Mẫu neo_sequence56 dài 11 có score 0.000162 nhưng là false negative. Đây là ví dụ lỗi được chọn theo confidence trong từng nhóm FP/FN, không phải mẫu chọn để hỗ trợ một câu chuyện sinh học thuận tiện.

Vì sao cần xem lỗi?. Metric tổng hợp có thể khá tốt trong khi một số dự đoán vẫn tự tin và sai. Hai hàng này minh họa giới hạn của score và sự cần thiết của kiểm tra mẫu cụ thể. Việc mẫu dài nhất bị sai không tự chứng minh mask padding có lỗi; muốn kiểm tra cần một phép kiểm chứng triển khai độc lập.

Các nguyên nhân vẫn là giả thuyết. Bối cảnh HLA thiếu, khác biệt miền dữ liệu, chất lượng nhãn hoặc similarity đều có thể là hướng điều tra, nhưng chưa được xác lập là nguyên nhân của các hàng này. Tập test chỉ có 61 dương, và chưa có cohort ngoài để đo khả năng khái quát sang nguồn mới.

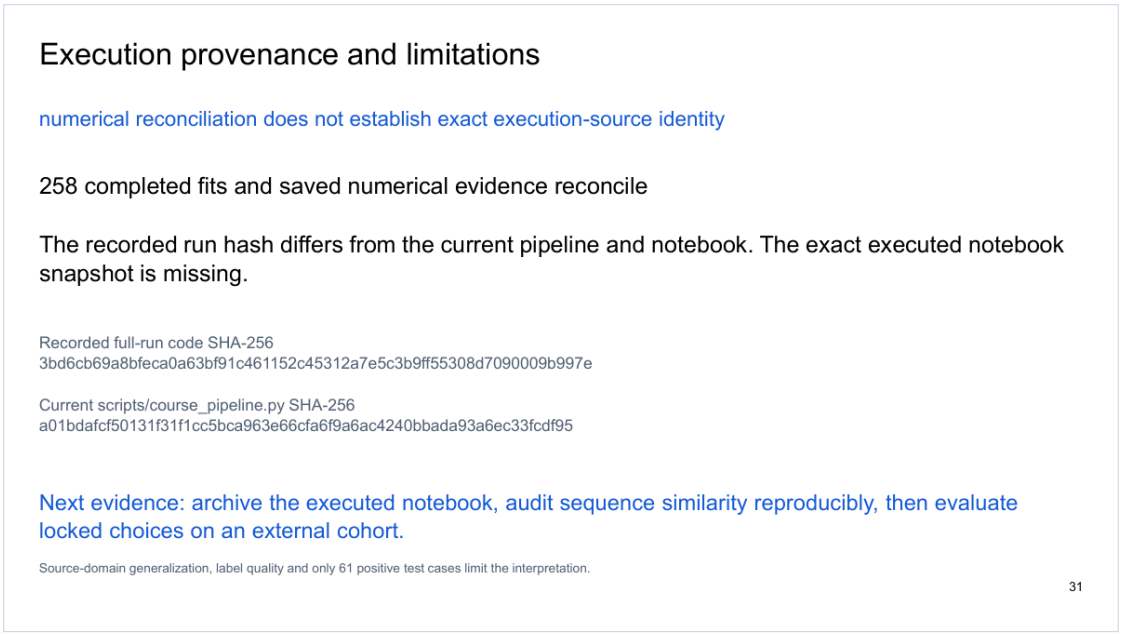
> **Ý cần nắm:** Một ví dụ lỗi có thể chỉ ra câu hỏi cần kiểm tra, nhưng không đủ tự xác nhận cơ chế gây lỗi.

Minh chứng: [S2], [S8]. Hình đối chiếu: slide 30 của PDF v3.

SLIDE 31

Kiểm tra số liệu và xác nhận đúng source là hai mức khác nhau

Execution provenance and limitations



Những gì đã được đối chiếu. Review tái tính 258 hàng metric per-run, 52 hàng test metric, tám ngưỡng OOF, 22 CV summary và 48 hàng bootstrap interval. Manifest có 1.580 file được kiểm tra và không phát hiện file thiếu hoặc hash sai trong phạm vi này. Đây là bằng chứng tích cực về tính nhất quán của hồ sơ đã cung cấp.

Khoảng trống provenance. Run ghi code SHA-256 bắt đầu bằng 3bd6cb69a8, trong khi source hiện tại có hash bắt đầu bằng a01bdafcf5. Notebook hiện tại nhúng source hash hiện tại; snapshot notebook/source thực sự đã chạy full run chưa nằm trong hồ sơ. Vì vậy, không thể nói source hiện tại giống từng byte với source đã tạo các kết quả.

Hệ quả thực tế. Báo cáo có thể xác nhận số liệu, ID, split và các lựa chọn đã lưu khớp nhau. Nó chưa chứng nhận một GPU rerun sạch sẽ tái tạo y hệt hoặc mọi thao tác nội bộ của source lịch sử. Cần khôi phục executed notebook để đóng khoảng trống này; chưa có chứng cứ xác định một thay đổi source cụ thể gây ra khác biệt nào.

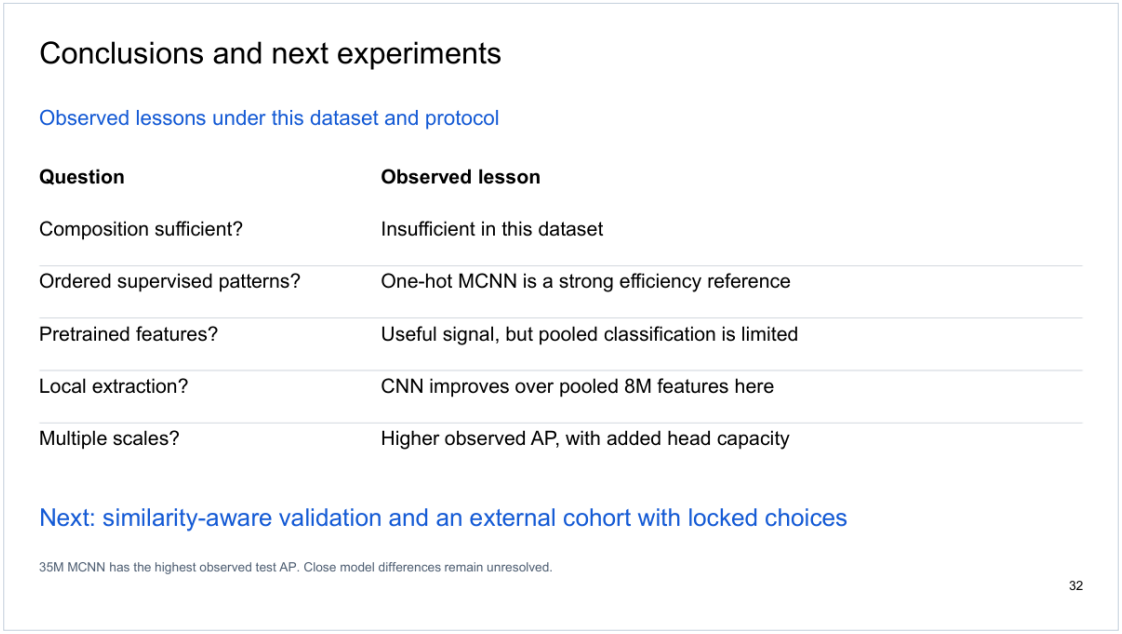
> **Ý cần nắm:** Numerical integrity đã có bằng chứng, còn exact execution provenance vẫn chưa khép kín.

Minh chứng: [S2], [S8]. Hình đối chiếu: slide 31 của PDF v3.

SLIDE 32

Những bài học đã đạt được và thí nghiệm kế tiếp

Conclusions and next experiments



Các câu hỏi đã có câu trả lời trong phạm vi dữ liệu. Composition đơn lẻ chưa đủ. One-hot MCNN là baseline mạnh và tiết kiệm. Frozen ESM chứa tín hiệu hữu ích, nhưng pooled LR chưa khai thác tốt bằng one-hot MCNN ở đây. CNN cải thiện trên pooled 8M, còn MCNN có AP quan sát cao hơn đi kèm head lớn hơn.

Kết luận về mô hình tốt nhất. 35M MCNN có AP cao nhất quan sát được và cũng đứng đầu CV selection. Tuy nhiên, dữ liệu chưa xác lập một người thắng đáng tin cậy giữa one-hot và hai ESM MCNN. Các MCC gần nhau không chứng minh tương đương; các khoảng paired chứa 0 cũng không chứng minh không có khác biệt thực.

Bước tiếp theo giải quyết đúng giới hạn. Ưu tiên khôi phục source đã chạy, kiểm tra similarity bằng protocol tái lập được và dùng grouped validation. Sau đó đánh giá các lựa chọn khóa trên cohort ngoài. Thí nghiệm parameter-matched heads và calibration bằng dữ liệu train-only sẽ làm rõ capacity và ý nghĩa score. Nếu thay mô hình dựa trên test đã xem, cần một tập đánh giá mới chưa bị sử dụng.

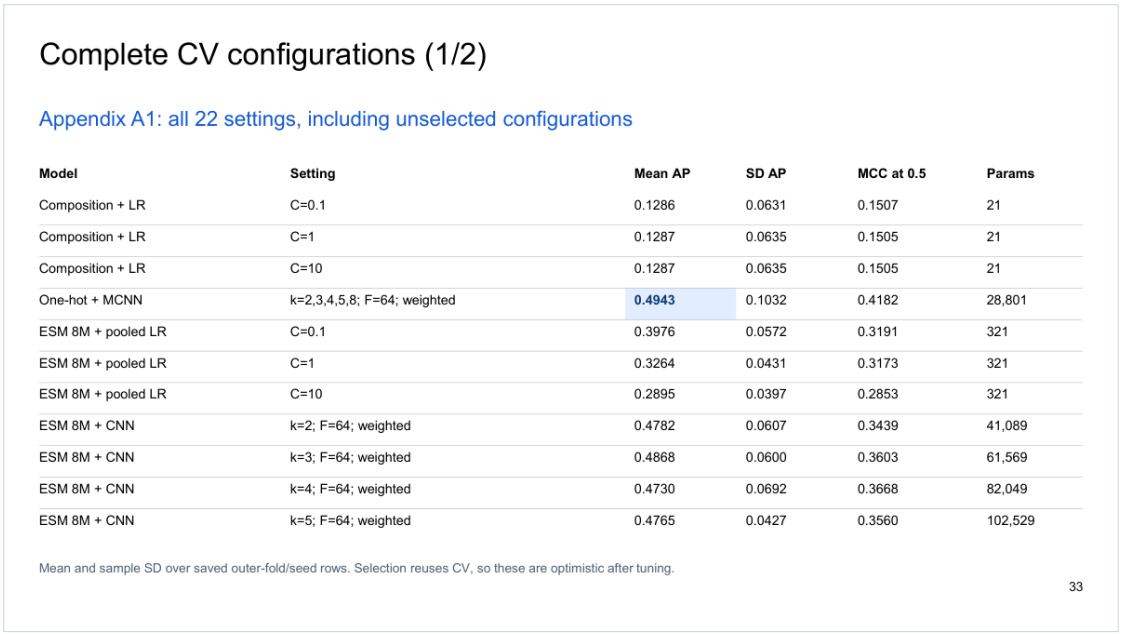
> **Ý cần nắm:** So sánh representation, kiến trúc, threshold, bất định và compute cùng nhau là thành quả phương pháp quan trọng nhất.

Minh chứng: [S2], [S3], [S8]. Hình đối chiếu: slide 32 của PDF v3.

SLIDE 33

Phụ lục CV (1/2): vì sao cần giữ cả cấu hình không được chọn?

Complete CV configurations (1/2)



Complete CV configurations (1/2)

Appendix A1: all 22 settings, including unselected configurations

Model	Setting	Mean AP	SD AP	MCC at 0.5	Params
Composition + LR	C=0.1	0.1286	0.0631	0.1507	21
Composition + LR	C=1	0.1287	0.0635	0.1505	21
Composition + LR	C=10	0.1287	0.0635	0.1505	21
One-hot + MCNN	k=2,3,4,5,8; F=64; weighted	0.4943	0.1032	0.4182	28,801
ESM 8M + pooled LR	C=0.1	0.3976	0.0572	0.3191	321
ESM 8M + pooled LR	C=1	0.3264	0.0431	0.3173	321
ESM 8M + pooled LR	C=10	0.2895	0.0397	0.2853	321
ESM 8M + CNN	k=2; F=64; weighted	0.4782	0.0607	0.3439	41,089
ESM 8M + CNN	k=3; F=64; weighted	0.4868	0.0600	0.3603	61,569
ESM 8M + CNN	k=4; F=64; weighted	0.4730	0.0692	0.3668	82,049
ESM 8M + CNN	k=5; F=64; weighted	0.4765	0.0427	0.3560	102,529

Mean and sample SD over saved outer-fold/seed rows. Selection reuses CV, so these are optimistic after tuning.

33

Nội dung của bảng. Bảng đầu liệt kê các cấu hình composition LR, one-hot MCNN, pooled 8M LR và một phần single-window CNN 8M. Mỗi hàng giữ setting, mean AP, SD AP, mean MCC ở 0.5 và số tham số. Các hàng không thắng vẫn là phần của cuộc khảo sát.

Cách đọc hợp lý. C là regularization của LR, k là chiều dài cửa sổ và F là filter mỗi nhánh. Ô xanh 0.4943 là cực đại AP trong phần bảng này, không phải cực đại toàn bộ 22 cấu hình. Một số mean làm tròn trông giống nhau, như composition C=1 và C=10, nên không nên suy ngược quyết định chọn chỉ từ bốn chữ số hiển thị.

Giá trị minh chứng. Bảng giúp kiểm tra rằng kết luận không chỉ được xây từ các run thuận lợi. Cấu hình được chọn dựa trên mean AP có độ chính xác lưu trong bảng gốc; quy tắc tie-break còn dùng MCC, số tham số và ID cấu hình. Các mean CV ở đây vẫn là selection scores, không phải nhiều independent test.

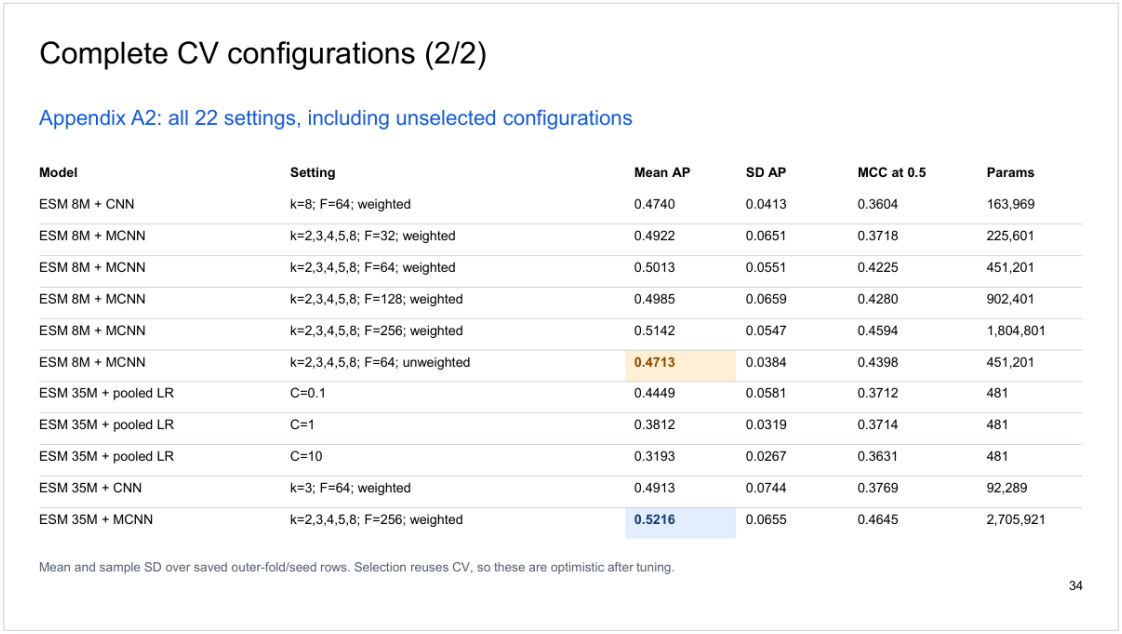
> **Ý cần nắm:** Lưu toàn bộ search space đã thử giúp đánh giá tính đầy đủ và tránh chỉ kể kết quả thuận lợi.

Minh chứng: [S3], [S5], [S12]. Hình đối chiếu: slide 33 của PDF v3.

SLIDE 34

Phụ lục CV (2/2): capacity, loss và encoder lớn hơn

Complete CV configurations (2/2)



Complete CV configurations (2/2)

Appendix A2: all 22 settings, including unselected configurations

Model	Setting	Mean AP	SD AP	MCC at 0.5	Params
ESM 8M + CNN	k=8; F=64; weighted	0.4740	0.0413	0.3604	163,969
ESM 8M + MCNN	k=2,3,4,5,8; F=32; weighted	0.4922	0.0651	0.3718	225,601
ESM 8M + MCNN	k=2,3,4,5,8; F=64; weighted	0.5013	0.0551	0.4225	451,201
ESM 8M + MCNN	k=2,3,4,5,8; F=128; weighted	0.4985	0.0659	0.4280	902,401
ESM 8M + MCNN	k=2,3,4,5,8; F=256; weighted	0.5142	0.0547	0.4594	1,804,801
ESM 8M + MCNN	k=2,3,4,5,8; F=64; unweighted	0.4713	0.0384	0.4398	451,201
ESM 35M + pooled LR	C=0.1	0.4449	0.0581	0.3712	481
ESM 35M + pooled LR	C=1	0.3812	0.0319	0.3714	481
ESM 35M + pooled LR	C=10	0.3193	0.0267	0.3631	481
ESM 35M + CNN	k=3; F=64; weighted	0.4913	0.0744	0.3769	92,289
ESM 35M + MCNN	k=2,3,4,5,8; F=256; weighted	0.5216	0.0655	0.4645	2,705,921

Mean and sample SD over saved outer-fold/seed rows. Selection reuses CV, so these are optimistic after tuning.

34

Nội dung còn lại. Bảng tiếp tục single CNN k=8, các MCNN 8M theo số filter và loss, rồi các head 35M. Nó hoàn tất 22 cấu hình. Các hàng 35M CNN dùng lựa chọn k/filter/loss chuyển từ 8M, nên không thể đọc bảng như một full factorial search trên mọi khả năng.

Hai ô đáng chú ý. Ô 0.5216 của 35M MCNN là mean CV AP cao nhất trong toàn bộ run. Ô 0.4713 của unweighted MCNN giúp nhận ra đối chiếu loss với hàng weighted 64 filter 0.5013. Số tham số tăng mạnh khi tăng F hoặc D, dù cùng nhãn kiến trúc “MCNN”.

Những suy luận cần tránh. SD thấp hơn không tự bảo đảm kết quả trên cohort ngoài. Một giá trị AP cao trong cùng dữ liệu tuning chưa là ước lượng hậu chọn không chệch. Bảng đầy đủ nên dùng để kiểm tra các tương phản đã nêu ở Results, không dùng để chọn lại sau khi đã biết test hoặc hứa rằng search lớn hơn chắc chắn tốt hơn.

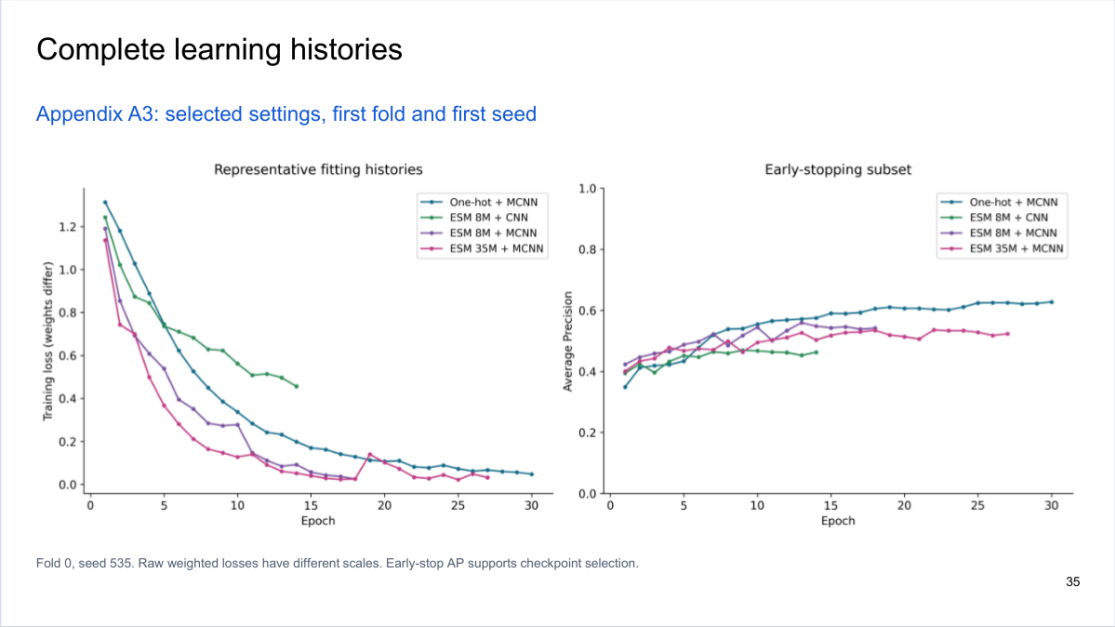
> **Ý cần nắm:** Hai trang CV cho phép truy lại đầy đủ cấu hình, chi phí capacity và các kết quả âm tính của quá trình tìm kiếm.

Minh chứng: [S2], [S3], [S5], [S12]. Hình đối chiếu: slide 34 của PDF v3.

SLIDE 35

Learning histories đầy đủ: bằng chứng chi tiết phía sau slide 18

Complete learning histories



Mối liên hệ với phần chính. Đây là bản đầy đủ của hình fitting loss và early-stop AP đã dùng ở Results. Nó không bổ sung một thí nghiệm mới, mà giữ một bản dễ kiểm tra các trục, legend và độ dài lịch sử của những cấu hình được chọn.

Quan sát có thể rút ra. Ở ví dụ fold 0, seed 535, loss giảm rõ còn AP có giai đoạn phẳng hoặc dao động. Các đường kết thúc ở epoch khác nhau do quá trình dừng và checkpoint. Không nên so chỉ số epoch cuối giữa hai đường như thể mọi mô hình đã học cùng một số bước hiệu quả.

Giới hạn của hình đại diện. Đây không phải mean curve của năm fold và ba seed. Muốn kết luận về độ ổn định học trên toàn bộ run cần xem các epoch histories và learning_summary đã lưu. Đường này hỗ trợ cách chọn checkpoint theo AP; nó không đủ tách nguyên nhân overfitting, capacity hay khó khăn của một partition cụ thể.

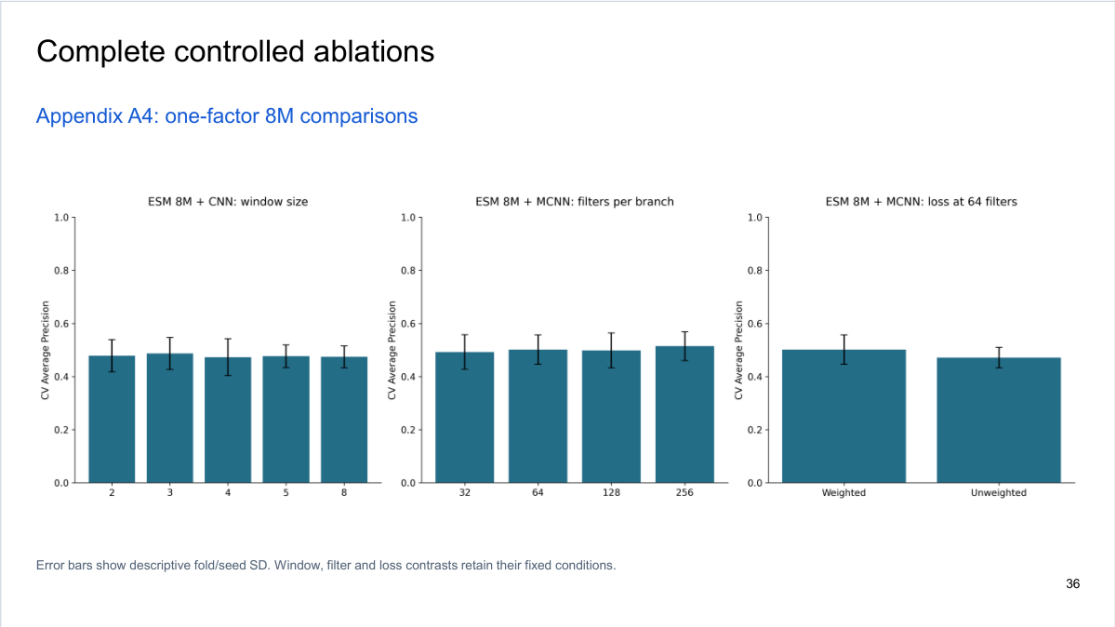
> **Ý cần nắm:** Phụ lục giữ bằng chứng gốc để kiểm tra một diễn giải đã nêu, không biến ví dụ đại diện thành kết luận cho mọi run.

Minh chứng: [S2], [S7]. Hình đối chiếu: slide 35 của PDF v3.

SLIDE 36

Ablation đầy đủ: kiểm tra các điều kiện giữ cố định

Complete controlled ablations



Mối liên hệ với slide 21. Hình ba panel giữ toàn bộ đối chiếu cửa sổ, filter và loss của ESM 8M. Nó cho phép kiểm tra xem một phát biểu ở phần chính có so đúng hai cấu hình tương ứng hay không. Không có hiệu ứng nhân quả sinh học nào được suy ra từ các thanh này.

Cách kiểm tra một phát biểu. Muốn kiểm tra ảnh hưởng loss, cần so weighted/unweighted ở 64 filter và cùng năm cửa sổ. Muốn kiểm tra filter, cần giữ weighted loss và bộ cửa sổ. Muốn kiểm tra k của single CNN, cần giữ 64 filter và representation. Nếu đồng thời đổi nhiều yếu tố, không thể quy chênh lệch cho một yếu tố duy nhất.

Kết quả cần giữ cả mặt không thuận lợi. Filter không cho xu hướng tăng AP đơn điệu; lợi ích weighted AP không đi cùng tăng MCC ở 0.5; khác biệt giữa các k khá hẹp so với spread. Các quan sát này là thành quả của nghiên cứu có kiểm soát, không phải kết quả “thất bại” cần bỏ khỏi báo cáo.

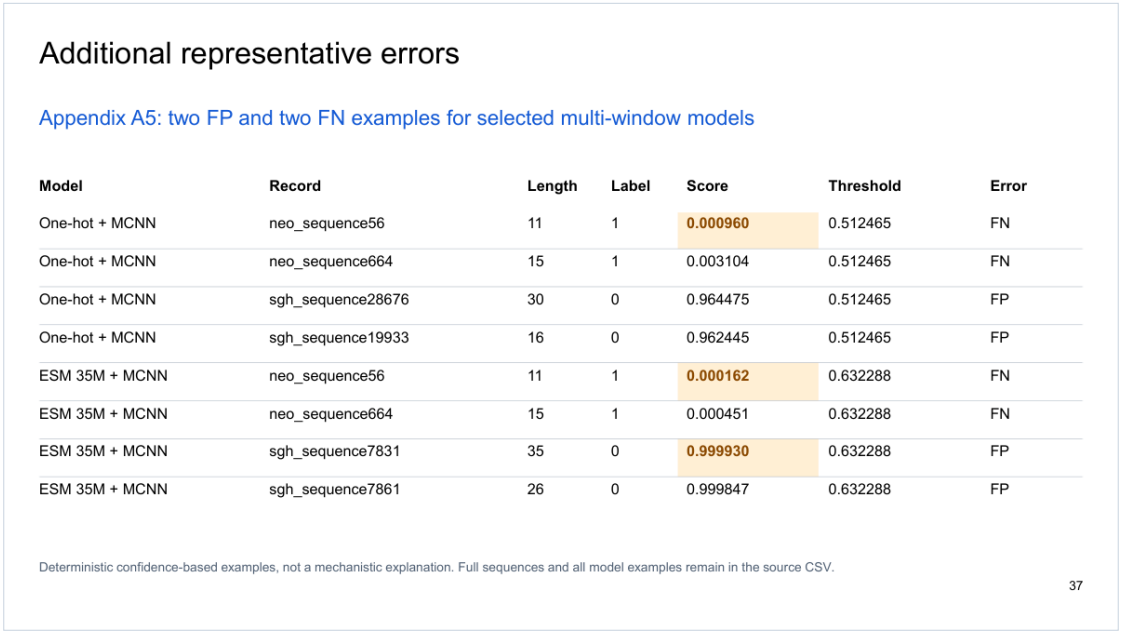
> **Ý cần nắm:** Một ablation chỉ có ý nghĩa trong điều kiện cố định đã nêu và với metric đang được so sánh.

Minh chứng: [S2], [S3], [S12]. Hình đối chiếu: slide 36 của PDF v3.

SLIDE 37

Ví dụ lỗi bổ sung và cách lựa chọn có thể tái kiểm tra

Additional representative errors



Additional representative errors

Appendix A5: two FP and two FN examples for selected multi-window models

Model	Record	Length	Label	Score	Threshold	Error
One-hot + MCNN	neo_sequence56	11	1	0.000960	0.512465	FN
One-hot + MCNN	neo_sequence664	15	1	0.003104	0.512465	FN
One-hot + MCNN	sgh_sequence28676	30	0	0.964475	0.512465	FP
One-hot + MCNN	sgh_sequence19933	16	0	0.962445	0.512465	FP
ESM 35M + MCNN	neo_sequence56	11	1	0.000162	0.632288	FN
ESM 35M + MCNN	neo_sequence664	15	1	0.000451	0.632288	FN
ESM 35M + MCNN	sgh_sequence7831	35	0	0.999930	0.632288	FP
ESM 35M + MCNN	sgh_sequence7861	26	0	0.999847	0.632288	FP

Deterministic confidence-based examples, not a mechanistic explanation. Full sequences and all model examples remain in the source CSV.

37

Những bản ghi được giữ. Bảng có hai false negative và hai false positive cho one-hot MCNN và 35M MCNN. Các ID, chiều dài, nhãn, score và ngưỡng được lấy từ representative_errors.csv. Theo hồ sơ phân tích, ví dụ được chọn theo confidence của lỗi trong nhóm, rồi dùng ID khi cần phân xử hòa.

Một quan sát giữa hai mô hình. neo_sequence56 xuất hiện như false negative ở cả hai. Điều này cho thấy một mẫu có thể khó cho nhiều cách biểu diễn, nhưng không chứng minh một nguyên nhân chung cụ thể. Các score giữa mô hình khác nhau cũng không nên so trực tiếp như các xác suất đã được hiệu chuẩn chung.

Dùng bảng để làm gì?. Bảng hỗ trợ kiểm tra hồ sơ, xem lại trình tự và hình thành giả thuyết cho nghiên cứu tiếp. Nó không phải một tập dữ liệu được chọn ngẫu nhiên để ước lượng tỷ lệ lỗi, cũng không đủ để kết luận cơ chế theo chiều dài. Không sửa threshold hoặc loại một mẫu test khó chỉ để tăng điểm đã báo cáo.

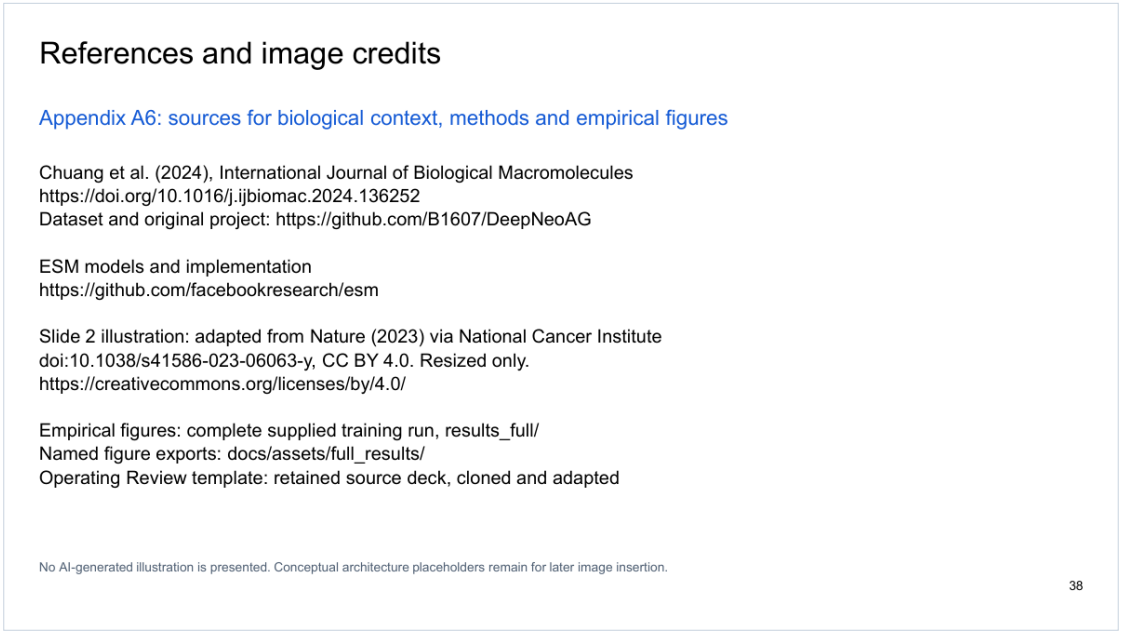
> **Ý cần nắm:** Error analysis cần quy tắc chọn ví dụ minh bạch và tách quan sát khỏi lời giải thích chưa được kiểm chứng.

Minh chứng: [S2], [S8]. Hình đối chiếu: slide 37 của PDF v3.

SLIDE 38

Tài liệu tham khảo và nguồn gốc hình ảnh

References and image credits



Ba loại nguồn khác nhau. Bài báo DeepNeoAG và repository tác giả xác định bối cảnh cùng nguồn dữ liệu. FAIR ESM cung cấp nền tảng encoder. Các bảng, predictions và log trong results_full là bằng chứng trực tiếp cho kết quả thí nghiệm của dự án. Chúng không thể thay thế lẫn nhau khi kiểm tra một phát biểu.

Nguồn hình và tài sản trình bày. Hình bối cảnh trên slide 3 được ghi công từ Nature qua National Cancer Institute theo CC BY 4.0. Các hình số liệu lấy từ full run đã cung cấp, với bản xuất có tên rõ trong docs/assets/full_results. Template Operating Review quyết định hình thức trình bày, không phải nguồn chứng minh kết quả nghiên cứu.

Nguồn ba sơ đồ đã hoàn thiện. Ba sơ đồ I, C, D ở slide 12-14 đã được dựng bằng code theo ngữ cảnh và cấu hình thực nghiệm, không sinh từ prompt cũ. Chúng là nhóm vector chỉnh sửa được trong PowerPoint, có PNG/SVG riêng; ma trận embedding chỉ để minh họa. Dòng ghi chú placeholder ở chân slide credits còn sót từ bản cũ. Trạng thái hoàn thiện cùng nguồn và vị trí cập nhật nằm trong [S13].

> **Ý cần nắm:** Mỗi kết luận cần đúng loại nguồn: protocol cho cách làm, predictions/tables cho số liệu và đăng ký nguồn cho hình minh họa.

Minh chứng: [S1], [S2], [S3], [S9], [S13]. Hình đối chiếu: slide 38 của PDF v3.

Toàn bộ quá trình đã hoàn thành những gì?

Giai đoạn	Kết quả hoặc artefact đã có
Dữ liệu	7.012 record, giữ train/test 5.608/1.404; nhãn, ID và nguồn được giữ. Audit không thấy chuỗi trùng chính xác hoặc giao train/test theo chuỗi giống hệt.
Tiền xử lý	Composition 20 chiều; one-hot tới 35 vị trí; metadata 7.012 embeddings cho mỗi encoder. Protocol quy định bỏ special token, masked mean và mask convolution windows.
Thiết kế và fitting	Tám họ mô hình, 22 cấu hình; 45 LR CV fit + 195 neural CV fit + 18 final refit = 258 fit. Learning history, thời gian và parameter count được lưu.
Lựa chọn	Cấu hình theo mean CV AP; tám threshold được tái tính từ OOF MCC. Dấu vết khóa lựa chọn có trước final completions trong hồ sơ log.
Test và độ bất định	52 hàng test metric gồm nhiều policy/aggregation; các bảng chính dùng ensemble, OOF-selected. Có 2.000 bootstrap resamples và paired differences thăm dò.
Review hồ sơ	Tái tính 258 per-run metric rows, 22 CV summaries, tám ngưỡng và 48 CI rows. Kiểm tra 1.580 manifest files không thấy thiếu hoặc mismatch trong phạm vi đó.

Phân biệt ghi nhận triển khai với điều đã chứng nhận

Các chi tiết xử lý feature và training được mô tả bởi protocol cùng source hiện tại. Vì code hash lịch sử khác source hiện tại, artefacts không tự chứng nhận mọi thao tác bên trong phiên bản lịch sử. Số liệu đã lưu và kiểm tra provenance phải được diễn giải ở hai mức khác nhau. [S2, S3, S8]

Về thời gian: stage_times.csv của hồ sơ cộng khoảng 40,42 phút; các mốc log khoảng 40,43 phút. Snapshot status 38,89 phút được chụp trước phần hoàn tất/export. Không cộng các số này với nhau. Đó là quan sát trên môi trường đã ghi, không phải benchmark triển khai. [S2]

Đã đạt được điều gì, và chưa thể kết luận điều gì?

Mốc so sánh	Test AP	MCC	TP / FP	Trainable head
One-hot MCNN	0.5408	0.5495	37 / 32	28.801
ESM 8M MCNN	0.5437	0.5512	33 / 22	1.804.801
ESM 35M MCNN	0.5758	0.5513	44 / 52	2.705.921

Thành quả khoa học

Dự án xác định được giới hạn của composition; xây được baseline one-hot mạnh; cho thấy local CNN extraction hữu ích trên frozen 8M embeddings; ghi nhận hiệu ứng loss và capacity không đồng nhất; và lượng hóa trade-off giữa AP, recall, false positives và compute.

Mức chắc chắn

35M MCNN đứng đầu AP quan sát được, nhưng paired CI của chênh AP với one-hot là [-0.0444,0.1151], với 8M MCNN là [-0.0522,0.0922]. Hai khoảng chứa 0 không xác lập vượt trội hoặc tương đương. Các metric ở trên mô tả split, threshold và mô hình đã khóa.

Điều còn thiếu

Chưa có cohort ngoài, calibration, xác minh độc lập similarity filtering hoặc executed source snapshot. Chưa có thí nghiệm tách capacity bằng parameter-matched heads. Không có kiểm chứng sinh học hoặc hiệu quả điều trị từ bộ score này.

Bước tiếp theo theo thứ tự hợp lý

Khôi phục notebook/source lịch sử; lập protocol similarity và grouped validation có thể tái lập; đánh giá lựa chọn khóa trên nguồn ngoài; rồi kiểm tra capacity và calibration bằng dữ liệu phát triển phù hợp. Khi dùng test đã xem để sửa mô hình, cần tập đánh giá mới.

Câu trả lời tổng quát: không chỉ có một score cuối. Thành quả là hiểu điều gì mỗi lựa chọn mô hình đã thêm vào, cái giá phải trả và giới hạn của bằng chứng. [S2, S3, S5, S8]

Danh mục nguồn và cách tự đối chiếu

Mọi đường dẫn dưới đây tính từ thư mục gốc dự án. Khi một mục liệt kê nhiều tên CSV sau dấu chấm phẩy, chúng thuộc cùng thư mục vừa nêu. [S1] xác định số slide, các mục còn lại giải thích phương pháp hoặc cung cấp số liệu.

[S1] Bộ slide v3 - nguồn trực tiếp để lập thứ tự và đối chiếu hình

outputs/presentation/DeepNeoAG_Operating_Review_2026-10-26_v3.pdf

[S2] Báo cáo thực nghiệm đầy đủ và giới hạn diễn giải

docs/FULL_RESULTS_REPORT.md

[S3] Protocol, thuật toán lựa chọn, xử lý feature và metric

docs/EXPERIMENT_PROTOCOL.md

[S4] Nguồn dữ liệu, split công bố và các kiểm tra ban đầu

data/README.md

[S5] Kết quả và lựa chọn mô hình

results_full/tables/selected_models.csv; cv_summary.csv; test_metrics.csv; test_confidence_intervals.csv

[S6] Encoder và chi phí trích xuất

results_full/tables/encoder_costs.csv

[S7] Learning, fold/seed và các hình kết quả

outputs/full_analysis/learning_summary.csv; fold_summary.csv; docs/assets/full_results/

[S8] Kiểm chứng, paired differences và lỗi đại diện

outputs/full_analysis/validation_receipt.json; paired_test_differences.csv; representative_errors.csv

[S9] Nguồn hình và credit/license

docs/VISUAL_ASSET_GUIDE.md; docs/assets/references/sources.json

[S10] Audit dữ liệu đã dùng trong run

results_full/data_audit/audit.json; fold_assignments.csv

[S11] Metadata embeddings và lựa chọn encoder

results_full/features/esm_8M.json; esm_35M.json

[S12] Search space và đối chiếu kiểm soát

results_full/config/experiment_registry.json; results_full/tables/ablations.csv; fixed_configuration_comparison.csv

[S13] Sơ đồ I, C, D trong bản v3 và nguồn cấu hình

docs/assets/generated/README.md; outputs/presentation/diagram_assets_v3.json

Tài liệu nền và credit

Chuang, Liu, Ou (2024), DeepNeoAG. DOI: 10.1016/j.ijbiomac.2024.136252. Dataset: https://github.com/B1607/DeepNeoAG

ESM models và implementation: https://github.com/facebookresearch/esm

Hình bối cảnh ở slide 3: Adapted from Nature (2023), DOI 10.1038/s41586-023-06063-y, via National Cancer Institute, CC BY 4.0. Credit cụ thể giữ trong [S9].